DATA ANALYTICS

DATA MANAGEMENT, DATA VIZ & TEXT MINING

Diplôme Sorbonne Data Analytics

DATA VISUALISATION

Avec Seaborn

Seaborn

- Seaborn est une bibliothèque de tracés statistiques spécialement conçue pour bien interagir avec Pandas DataFrames afin de créer des types de tracés statistiques courants.
- Seaborn est construit directement à partir de Matplotlib mais utilise une syntaxe « sur une ligne » plus simple.
- Lorsque nous utilisons Seaborn, nous troquons la personnalisation contre la facilité d'utilisation.
- Cependant, comme il est construit directement à partir de Matplotlib, nous pouvons toujours effectuer des appels à la méthode plt pour affecter directement le tracé résultant.

Seaborn

- Un tracé Seaborn typique utilise une ligne de code, par exemple :

  sns.scatterplot(x='salaire',y='ventes',data=df)

- Seaborn prend un DataFrame pandas, puis l'utilisateur fournit les noms de colonnes correspondants pour x et y (en fonction du type de tracé)

Seaborn

- Dans cette section, nous nous concentrons sur la compréhension des cas d'utilisation de chaque tracé et de leur syntaxe Seaborn.
- Documentation en ligne : https://seaborn.pydata.org/
- Question courante des étudiants :
  « Comment puis-je choisir quel graphique utiliser ? »

Seaborn

- Sujets des sections :
  - Nuages de points
  - Graphes de distribution
  - Graphes catégoriels
  - Graphiques de comparaison
  - Grilles Seaborn
  - Tracés matriciels

Nuages de points

Nuages de points

- Les nuages de points montrent la relation entre deux variables continues.

- **Rappel :**
  Les variables continues sont des variables numériques qui peuvent prendre n'importe quel nombre de valeurs entre deux valeurs quelconques.

- Exemples de fonctionnalités continues
  - *Âge*
  - *Hauteur*
  - *Salaire*
  - *Température*
  - *Des prix*

Nuages de points

- Une variable continue permet à une valeur de toujours être comprise entre deux valeurs.

- A ne pas confondre avec une variable catégorielle qui représente des catégories distinctes et uniques :
  - Couleurs
  - Formes
  - Des noms

Nuages de points

- Les nuages de points alignent un ensemble de deux variables continues et les tracent sous forme de coordonnées.

- Par exemple, imaginez des employés salariés qui vendent un certain montant d'articles chaque année. Nous pourrions explorer la relation entre les salaires des employés et le montant des ventes.

Nuages de points

- Tracer les points de coordonnées (x, y)

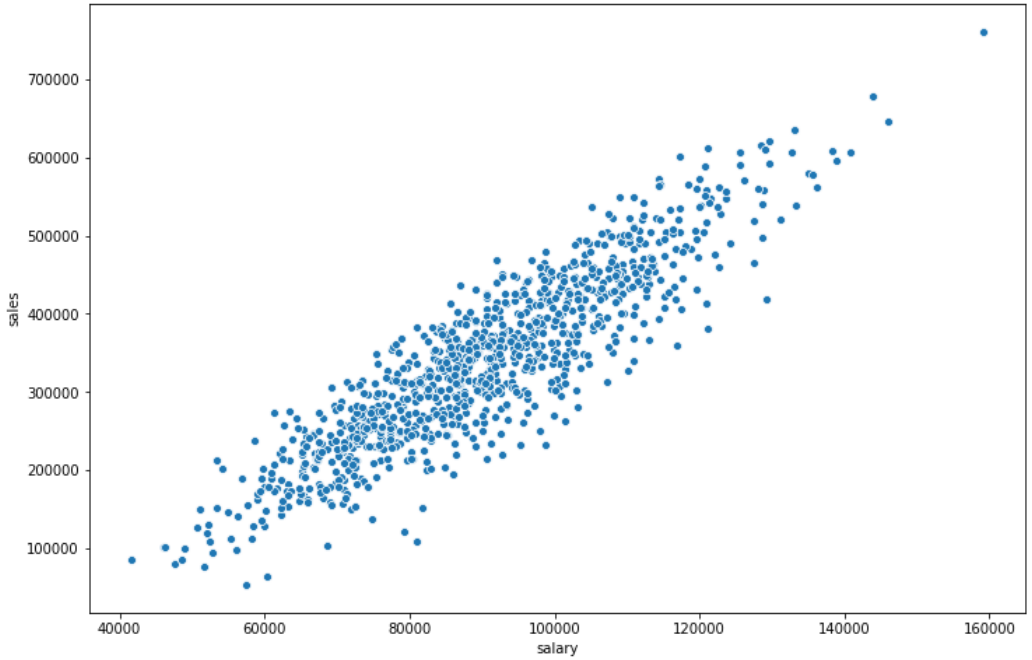

Nuages de points

- Tracer les points de coordonnées (salaire, ventes)

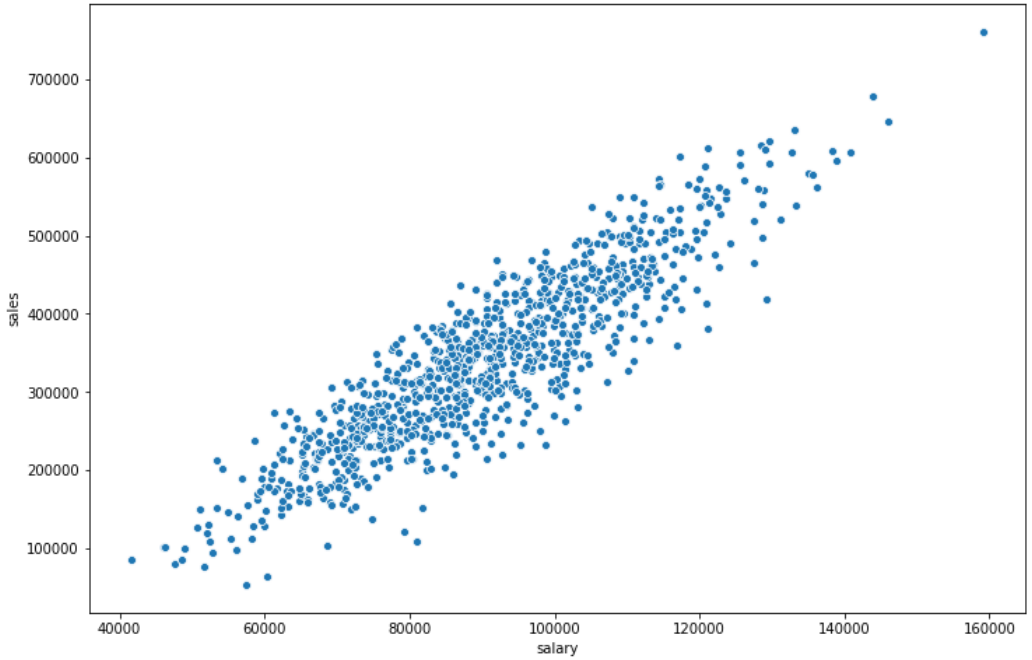

Nuages de points

- Seaborn peut ensuite ajouter de la coloration et du style
- Encodage par couleur / Nuage de points à trois dimensions (2D + couleur)
- Intérêt : Détecter si la troisième variable (l'expérience) influence la relation entre les deux premières.

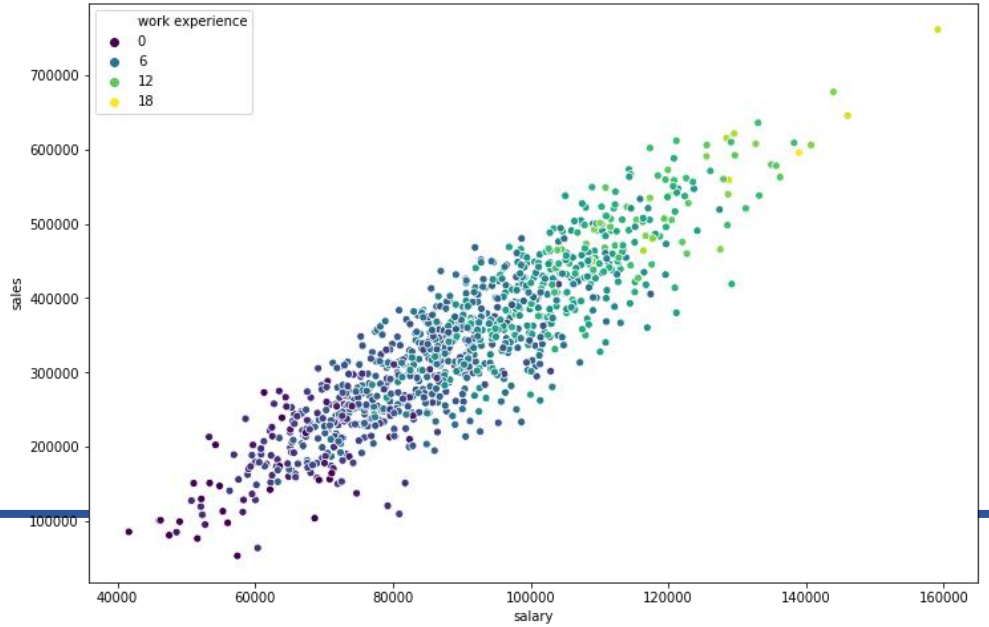

Nuages de points

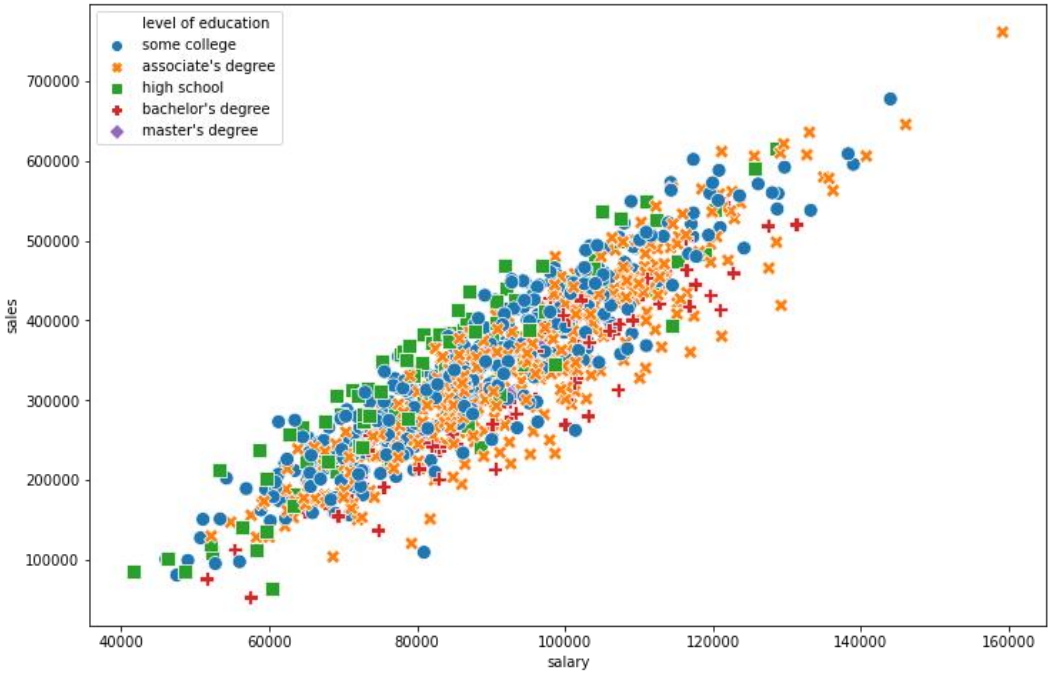

Notebook 1 : ScatterPlots

Graphes de distribution

Graphes de distribution

- Les diagrammes de distribution affichent une seule entité continue et permettent de visualiser des propriétés telles que l'écart et les valeurs moyennes.
- Ils sont utiles pour visualiser la fréquence ou la densité des valeurs d'une variable, ainsi que pour identifier des tendances ou des modèles dans la distribution des données.
- Il existe 3 principaux types de graphes de distribution :
  - Rug plot
  - Histogramme
  - KDE plot

Graphes de distribution

- Explorons la distribution des salaires des employés.
- Une façon d’y parvenir consiste à créer un rug plot.
- Un rug plot est le tracé de distribution le plus simple car il ajoute simplement un tiret ou une ligne de graduation pour chaque valeur.
- L’axe des y n’a pas vraiment de signification.

Graphes de distribution

- Graphique des salaires :
  - Ajoute une ligne pour chaque valeur de salaire

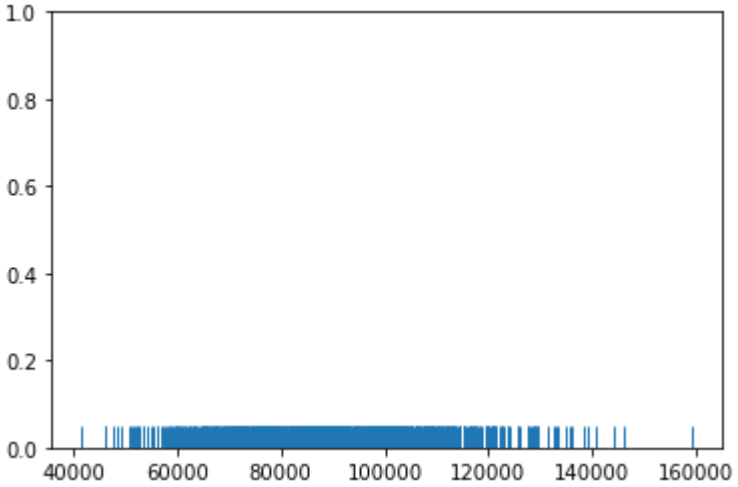

Graphes de distribution

- Graphique des salaires :
  - Ajustez éventuellement la hauteur des lignes

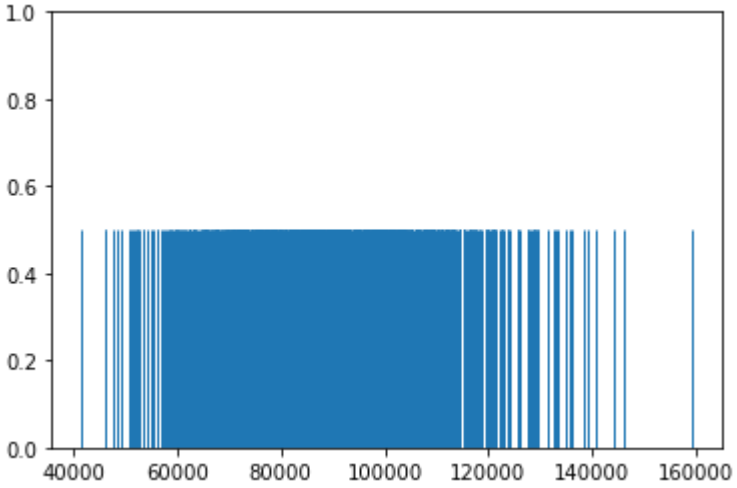

Graphes de distribution

- Graphique des salaires :
  - L'axe Y n'est pas interprétable

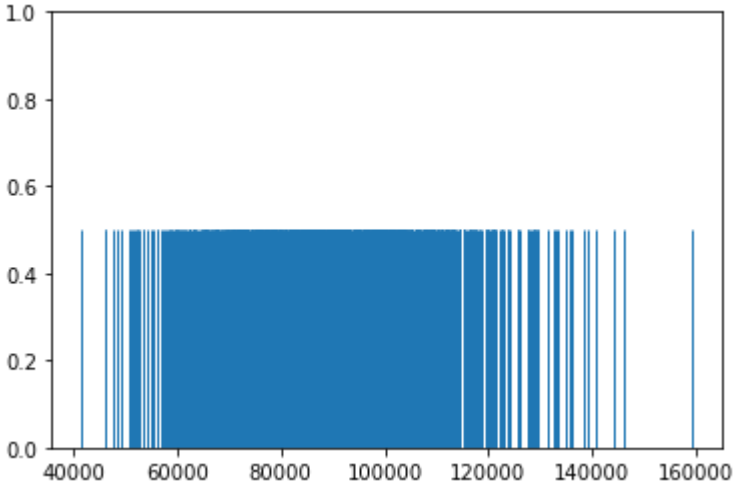

Graphes de distribution

- Graphique des salaires :
  - Salaire le plus élevé, près de 160 000 $

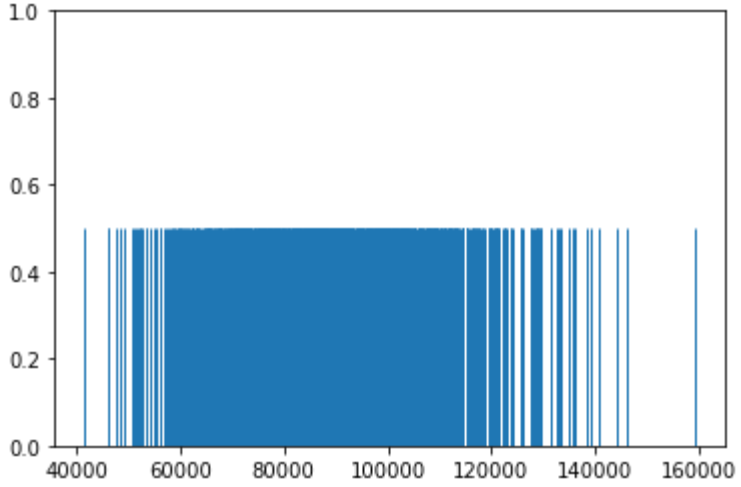

Graphes de distribution

- Graphique des salaires :
  - De nombreux salaires entre 60 000 $ et 120 000 $

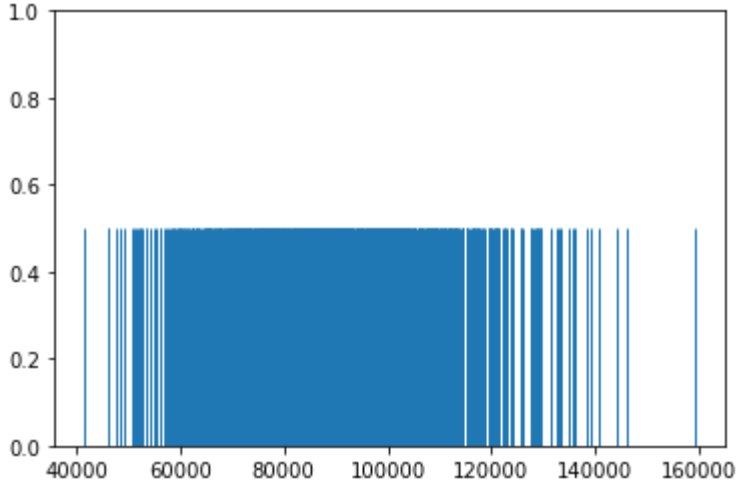

Graphes de distribution

- Graphique des salaires :
  - De nombreuses lignes peuvent être superposées, on ne peut pas le savoir !

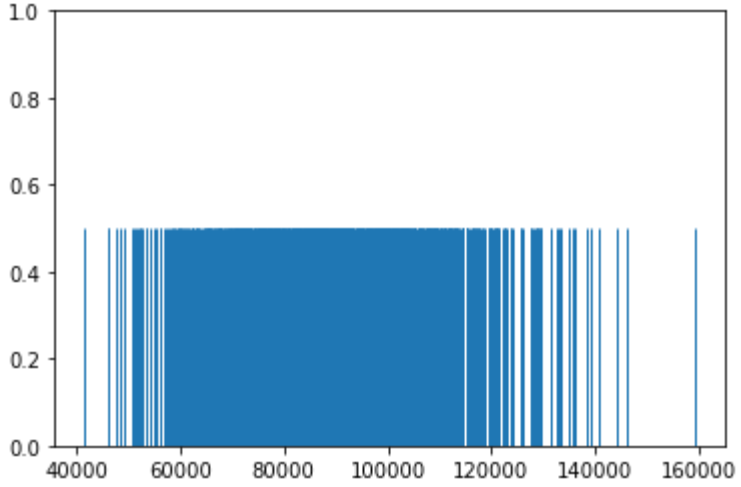

Graphes de distribution

- Graphique des salaires :
  - Si nous comptons combien de lignes il y a par plage de X, nous pouvons créer un histogramme

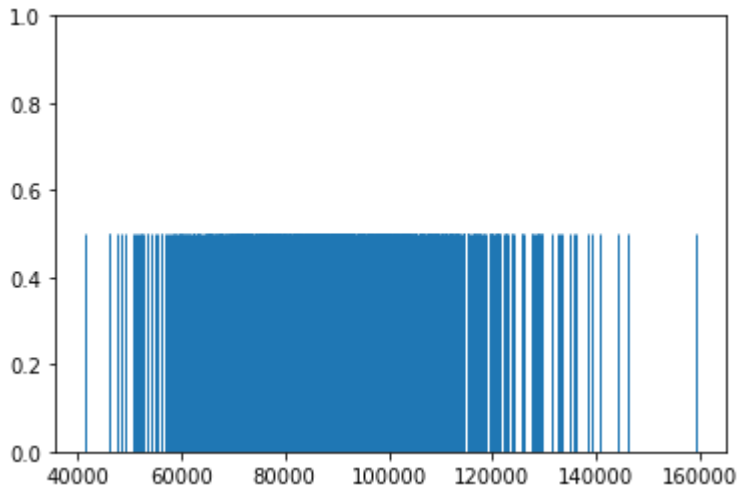

Graphes de distribution

- Explorons un exemple simple

Graphes de distribution

- Nous plaçons les lignes du rug plot

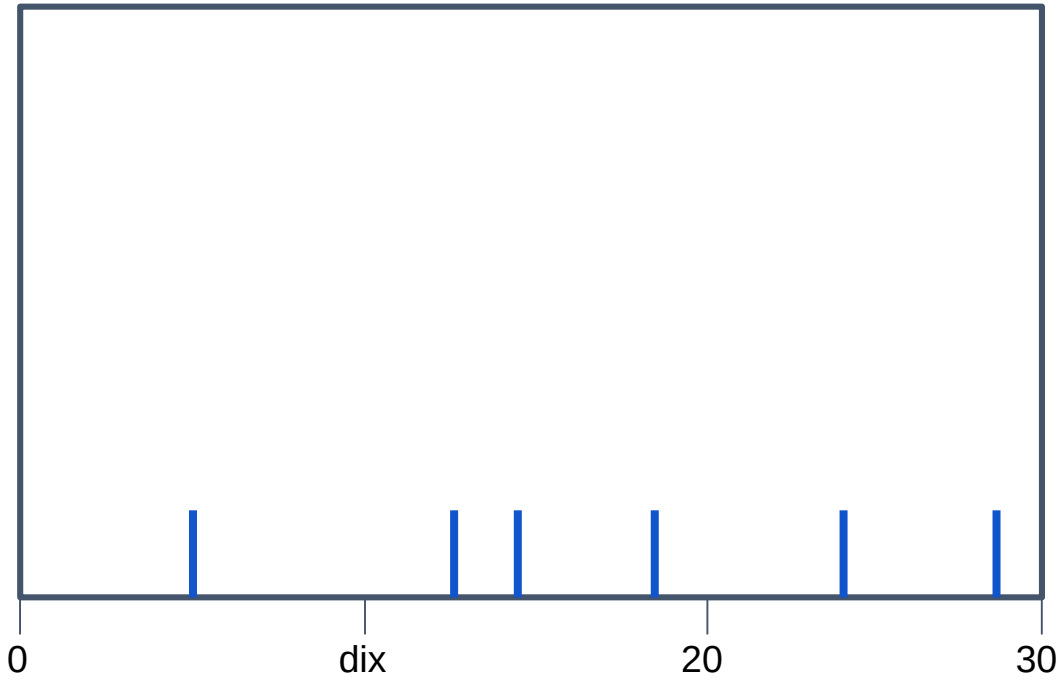

Graphes de distribution

- Choisissez un nombre de « groupes », nous en choisirons 3

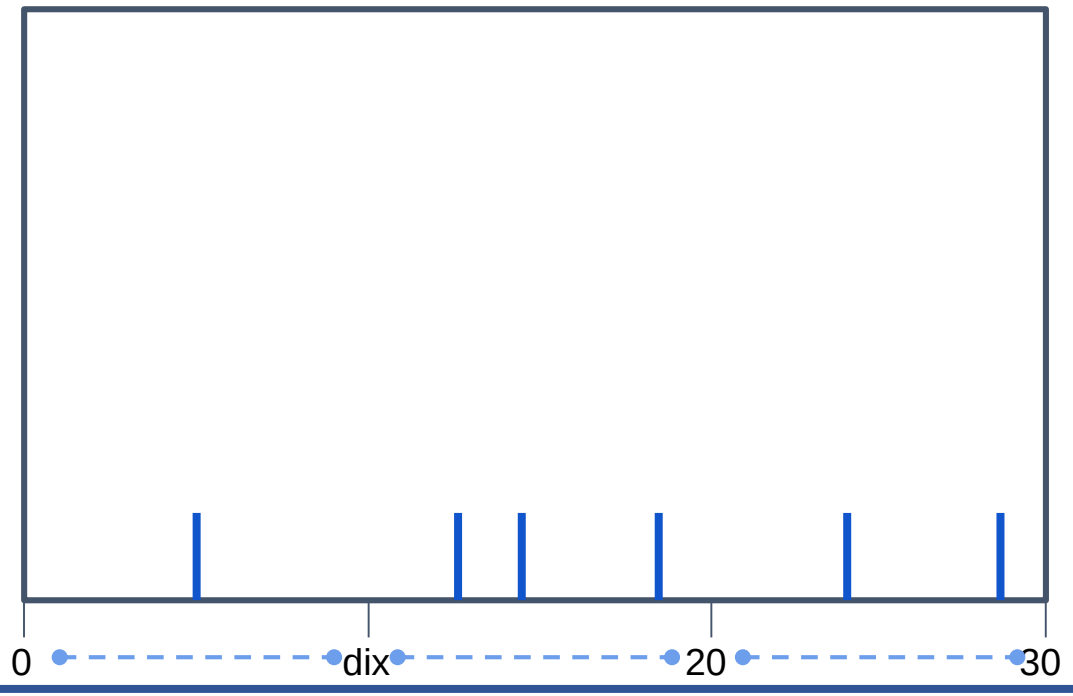

Graphes de distribution

- Compter les lignes par groupe

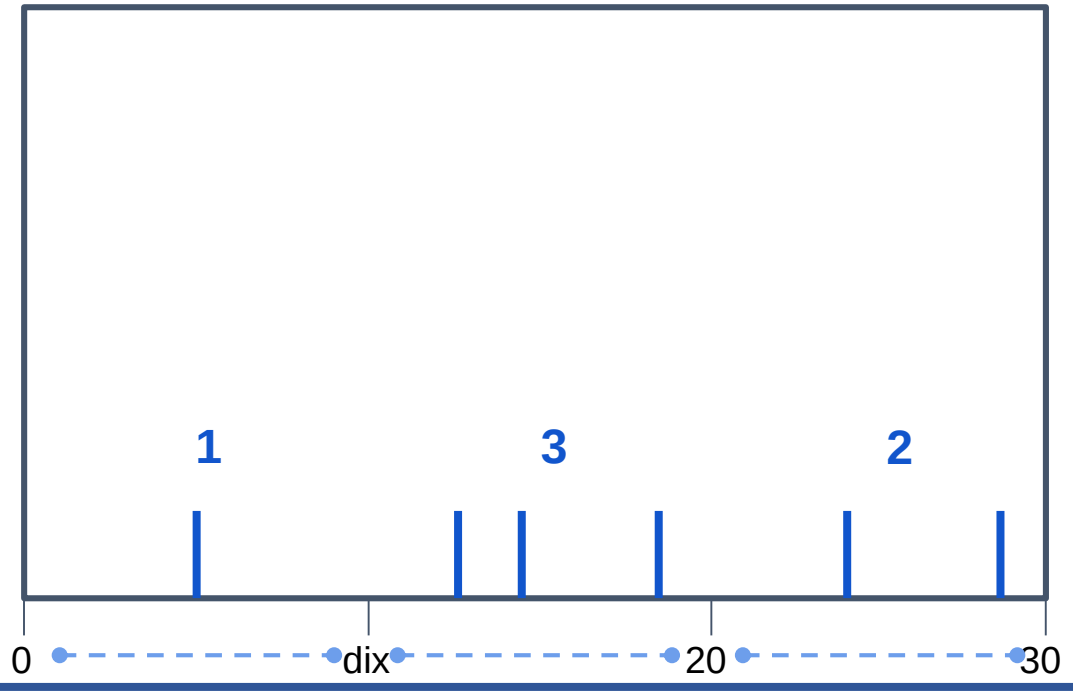

Graphes de distribution

- Créez une barre aussi haute que le nombre

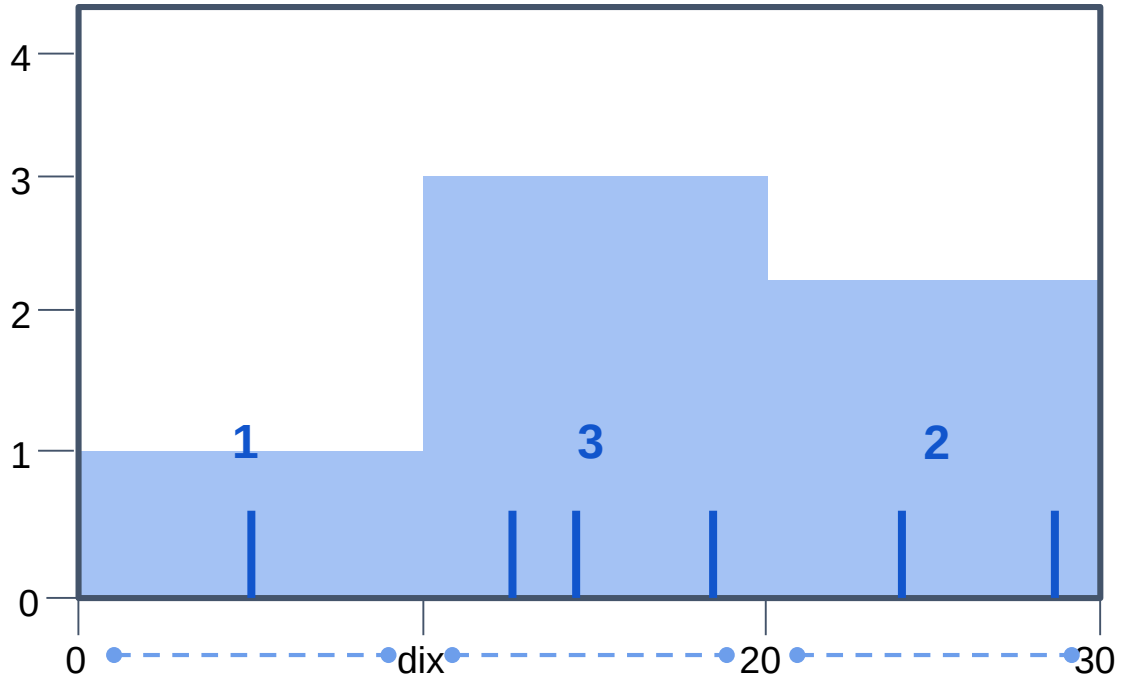

Graphes de distribution

- L'histogramme est terminé

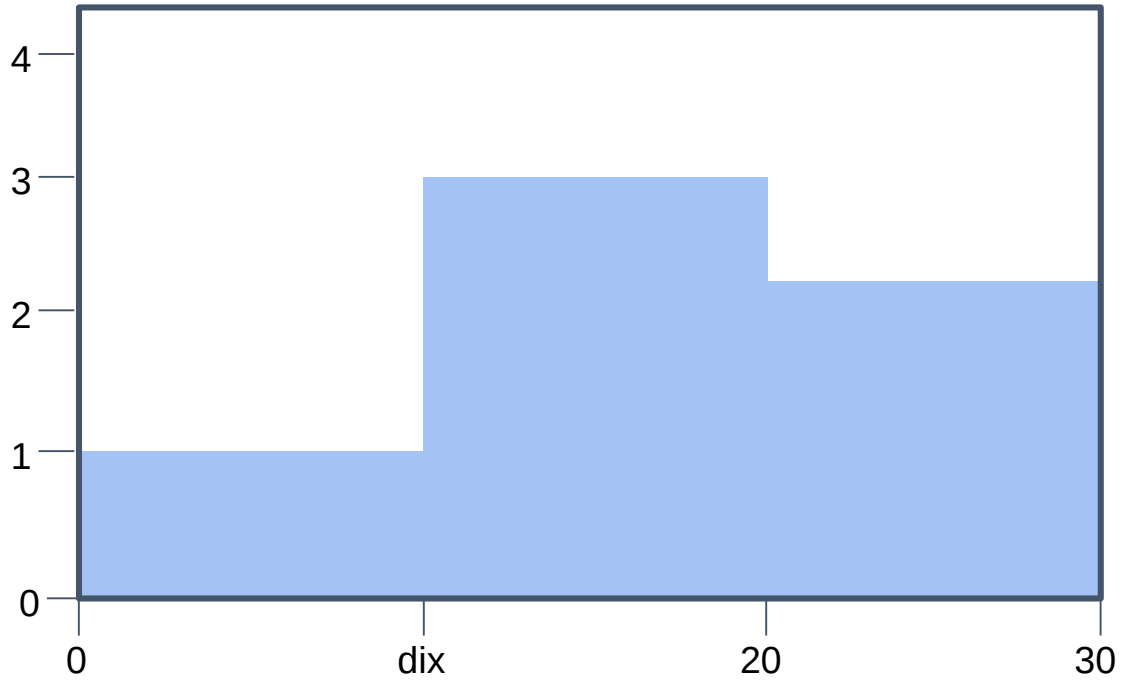

Graphes de distribution

- L'axe Y peut également être normalisé en pourcentage

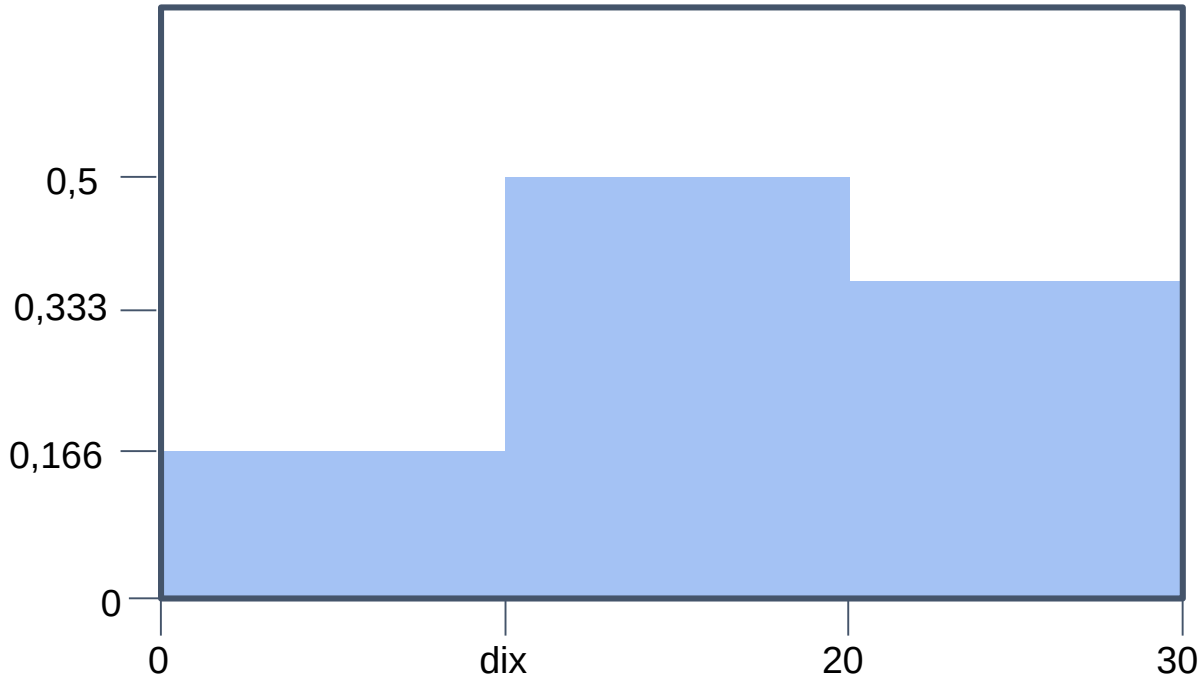

Graphes de distribution

- La modification du nombre de groupes affiche plus de détails au lieu de tendances générales.

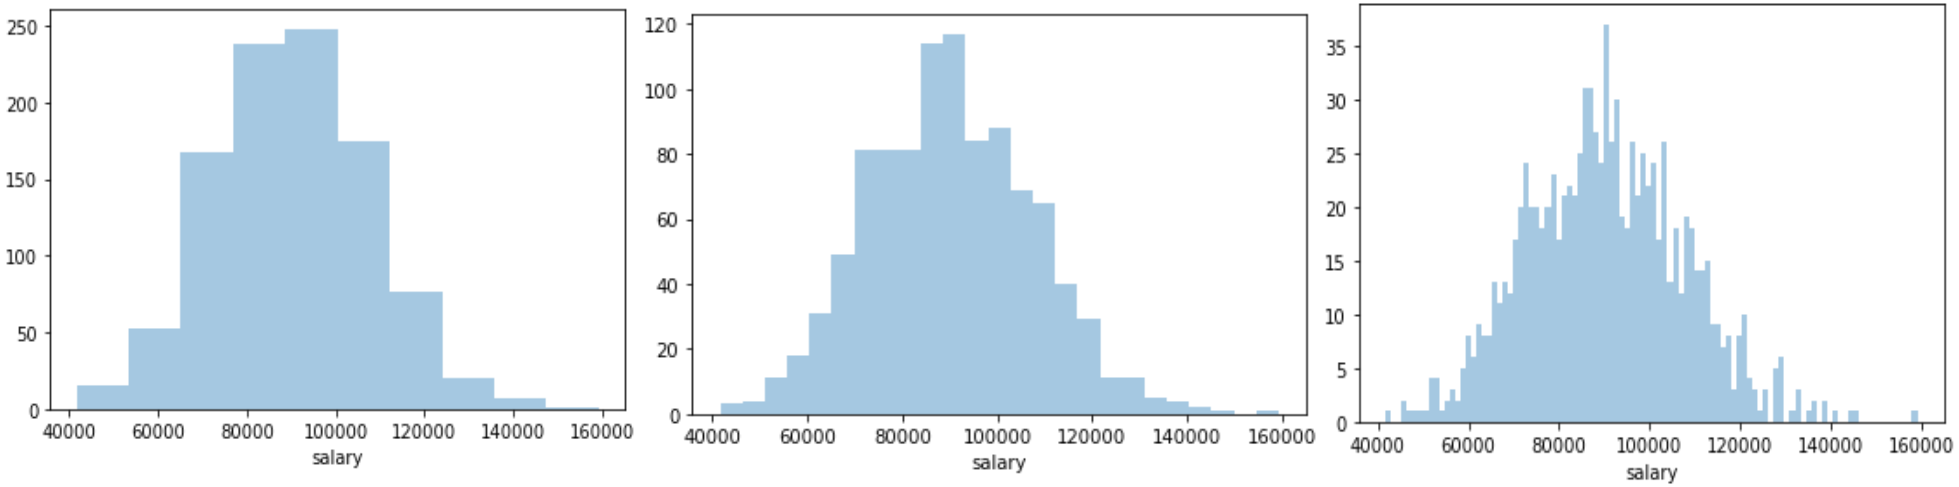

Graphes de distribution

- Seaborn nous permet également d'ajouter une courbe KDE (Kernel Density Estimate) par-dessus un histogramme.

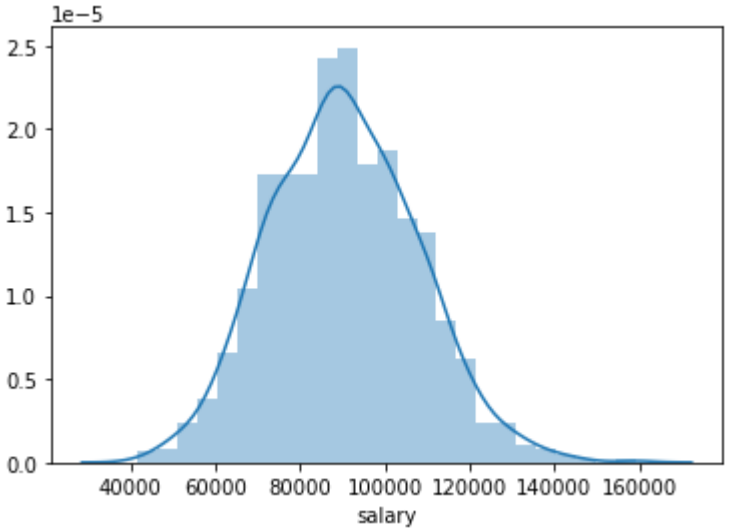

Graphes de distribution

- KDE signifie « Estimation de la densité du noyau » .

- Une courbe lissée qui estime la densité de probabilité des données (courbe qui montre où les valeurs sont fréquents et où elles sont rares)
- Version lissée et continue du comptage de l’histogramme.

Notebook 2 : Graphes de distribution

Graphes catégoriels

Estimation statistique au sein des catégories

Graphes catégoriels

- Les graphiques catégoriels discutés ici afficheront une métrique statistique par catégorie.
- Par exemple, la valeur moyenne par catégorie ou le nombre de lignes par catégorie.
- C'est l'équivalent de visualisation d'un appel groupby().
- Les deux principaux types de graphes pour cela sont :
  - countplot() : représenter graphiquement le nombre d'occurrences de chaque catégorie.
  - barplot() : visualiser les différences de magnitude entre les catégories ou groupes.

Graphes catégoriels

- Countplot pour les divisions d'une entreprise

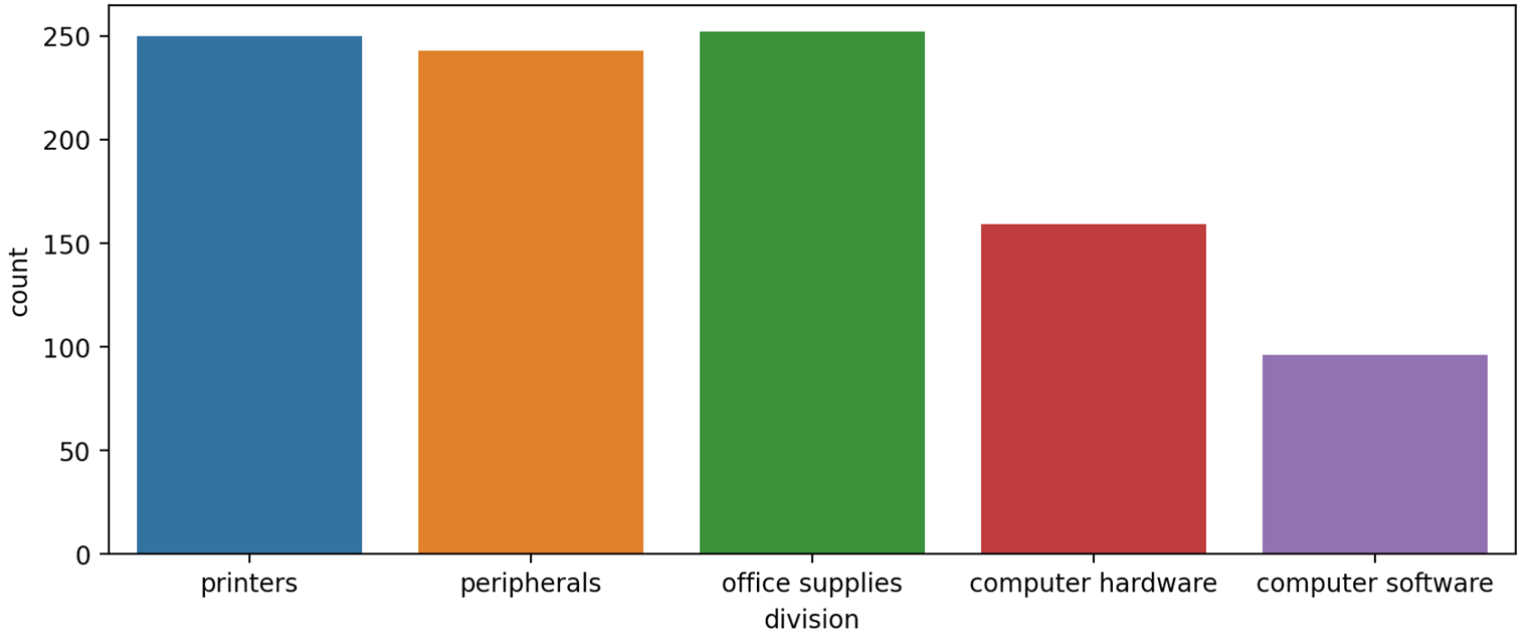

Graphes catégoriels

- Countplot pour les niveaux d’éducation

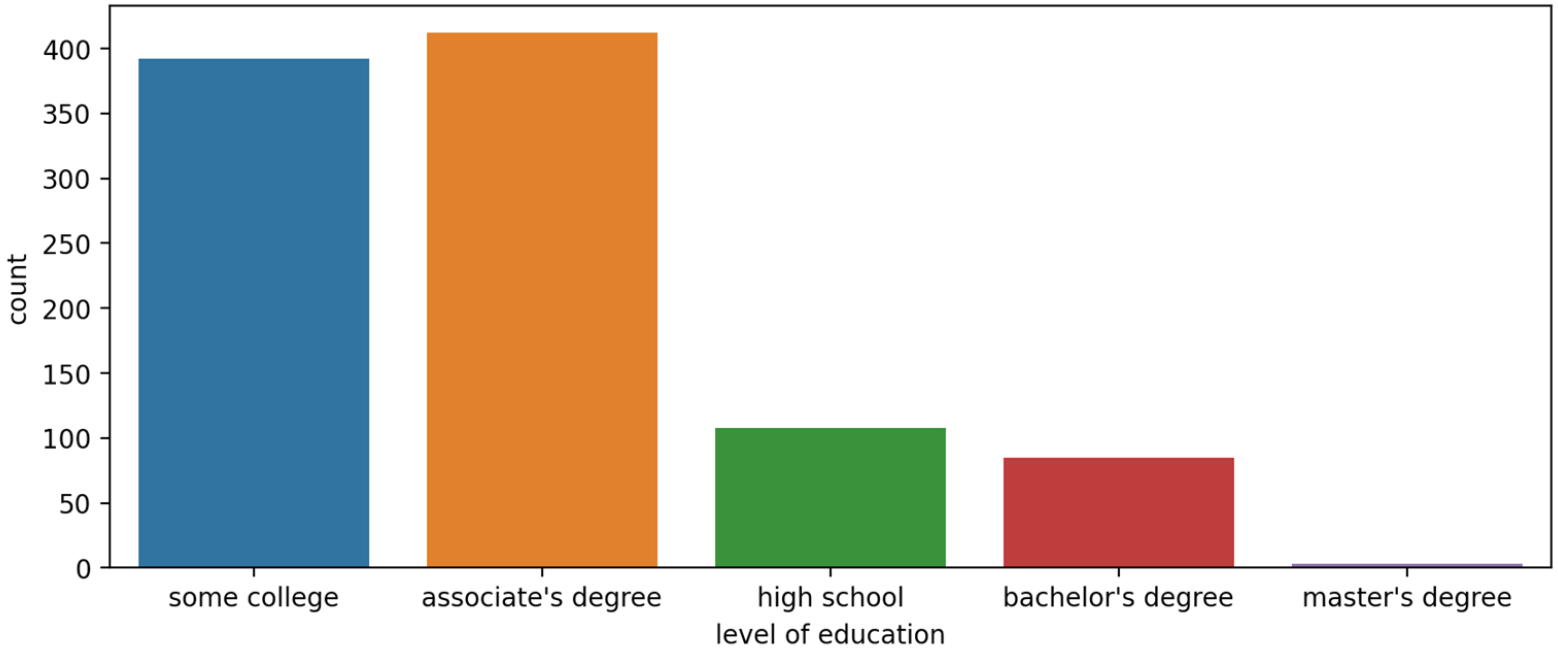

Graphes catégoriels

- Countplot avec séparation de teinte (hue) supplémentaire

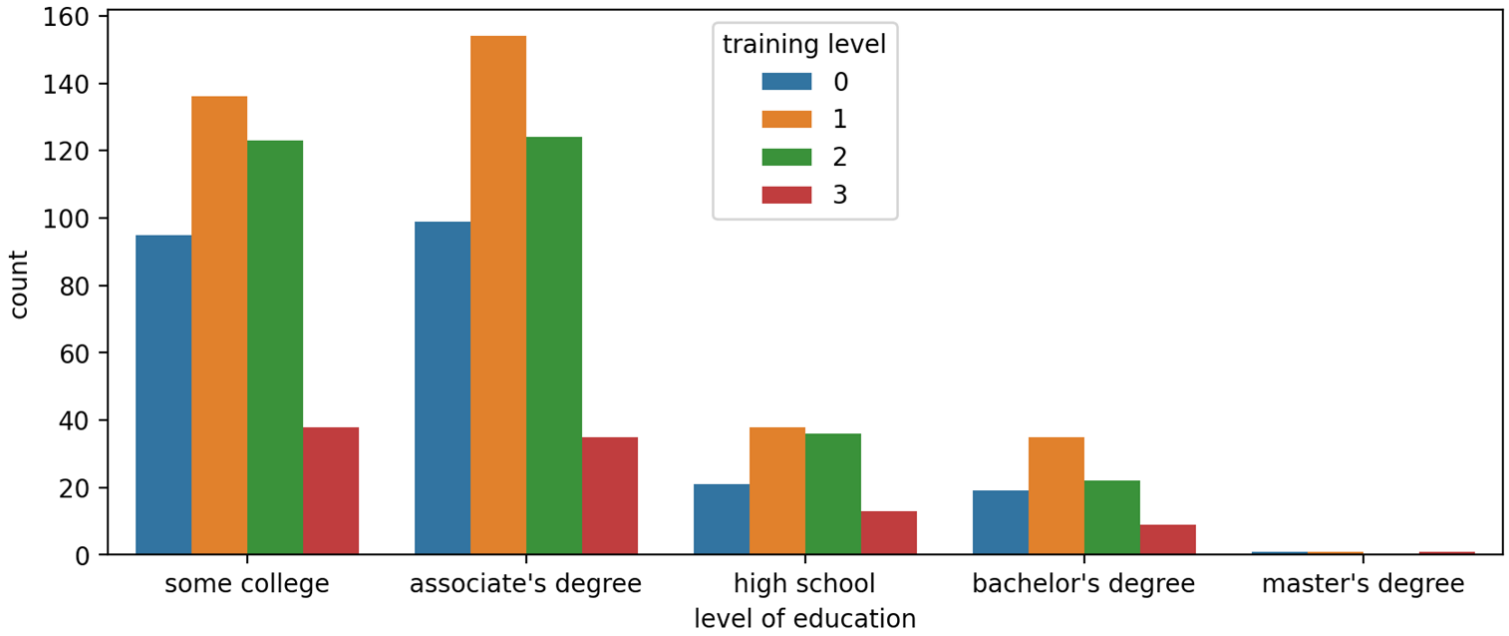

Graphes catégoriels

- Le barplot est la forme générale qui vous permet de choisir n'importe quelle mesure ou estimateur pour l'axe y.

- Nous pourrions plutôt tracer la valeur moyenne et l'écart type par catégorie.

- **Note importante** :
  - Soyez très prudent avec ces tracés, puisque la barre est remplie et continue, un utilisateur peut interpréter la continuité le long de l'axe y, ce qui peut être incorrect !
  - Assurez-vous toujours d'ajouter des étiquetages et des explications supplémentaires pour ces graphes !

Graphes catégoriels

- Barplot affichant les moyennes des salaires par niveau d'éducation

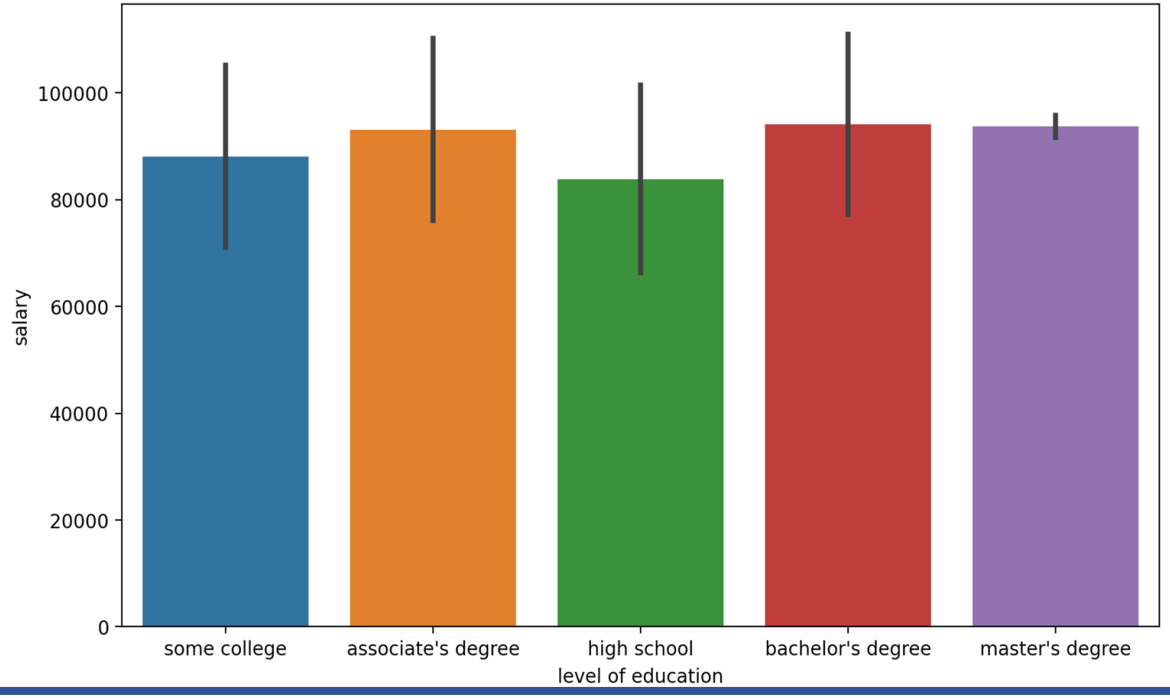

Pie Chart

- Un pie chart est généralement utilisé pour représenter la répartition des valeurs d'une variable catégorielle sous forme de parts d'un tout. Il est utile pour visualiser la contribution de chaque catégorie à l'ensemble des données et pour comparer les proportions des différentes catégories.

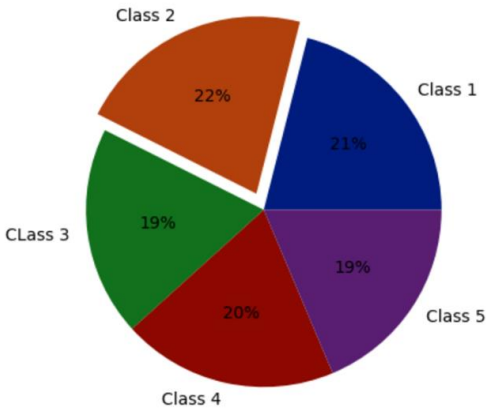

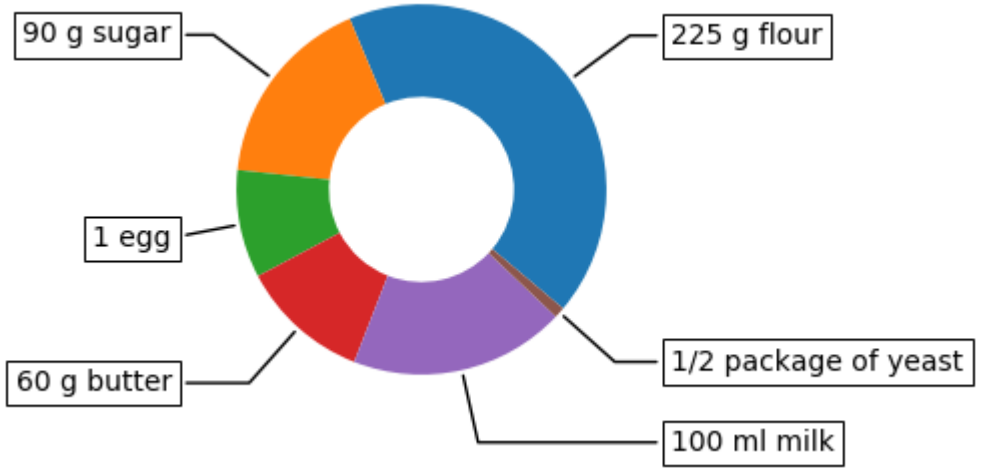

WordCloud

- Le nuage de mots (ou "word cloud" en anglais) est une représentation visuelle de données textuelles où les mots sont affichés en taille proportionnelle à leur fréquence d'apparition dans le texte. C'est une manière efficace de résumer et de visualiser les informations textuelles de manière concise et intuitive

Notebook 3 : Graphes catégoriels – *Estimation Statistique*

Graphes catégoriels

Distribution au sein des catégories

Graphes catégoriels

- Nous avons exploré les diagrammes de distribution pour une seule fonctionnalité, mais que se passe-t-il si nous voulons comparer les distributions entre catégories ?

- Par exemple, au lieu de la répartition des salaires de chacun, on peut comparer les répartitions des salaires par niveau.

- Nous allons d'abord séparer chaque catégorie, puis créer la visualisation de distribution.

- Plots possibles pour la répartition au sein des catégories :
  - Boxplot : Boîte à moustaches
  - Violinplot
  - Swarmplot
  - Boxenplot (tracé lettre-valeur)

Graphes catégoriels

- Le Boxplot affiche la distribution d'une variable continue.
- Pour ce faire, il utilise des quartiles.
- Les quartiles séparent les données en 4 nombres égaux de points de données :
  - 25 % des points de données se situent dans le quartile inférieur.
  - Le 50e percentile (Q2) est la médiane.

Graphes catégoriels

- Boîte à moustaches sur une seule entité :

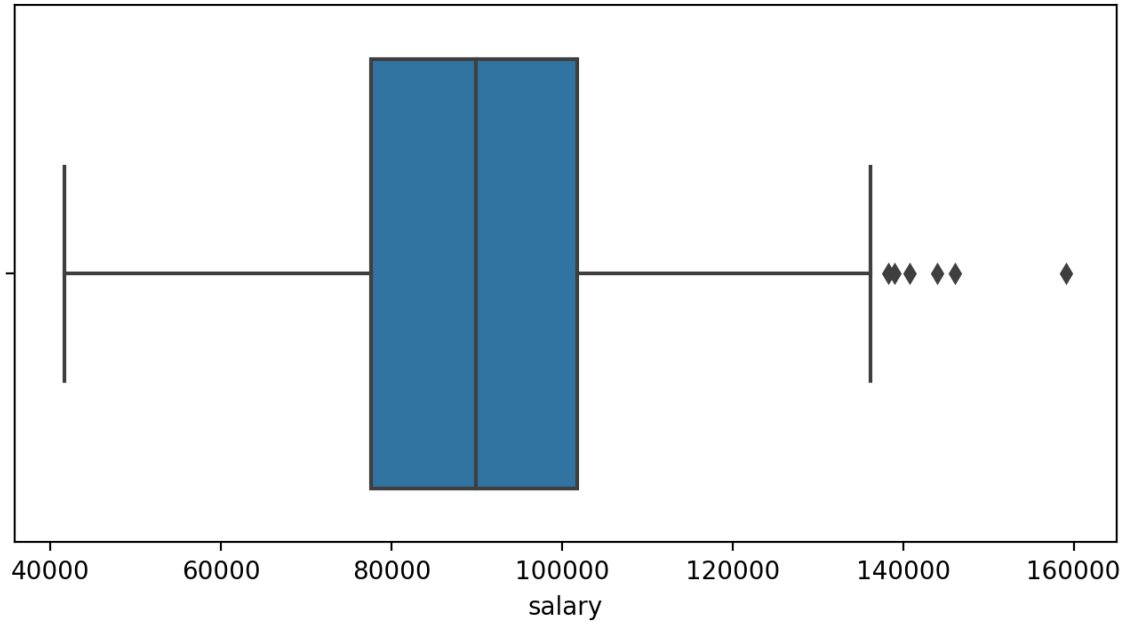

Graphes catégoriels

- La médiane est le 50e percentile

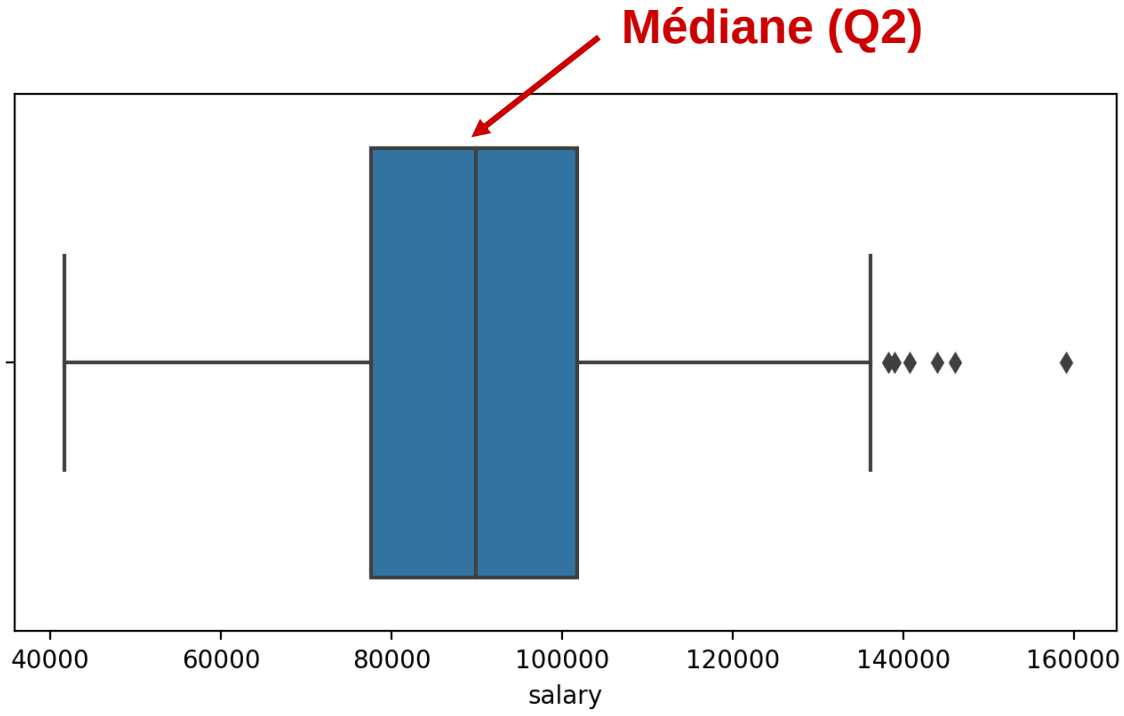

Graphes catégoriels

- La médiane divise les données en deux
- 50 % des valeurs sont inférieures ou égales, et 50 % sont supérieures ou égales.

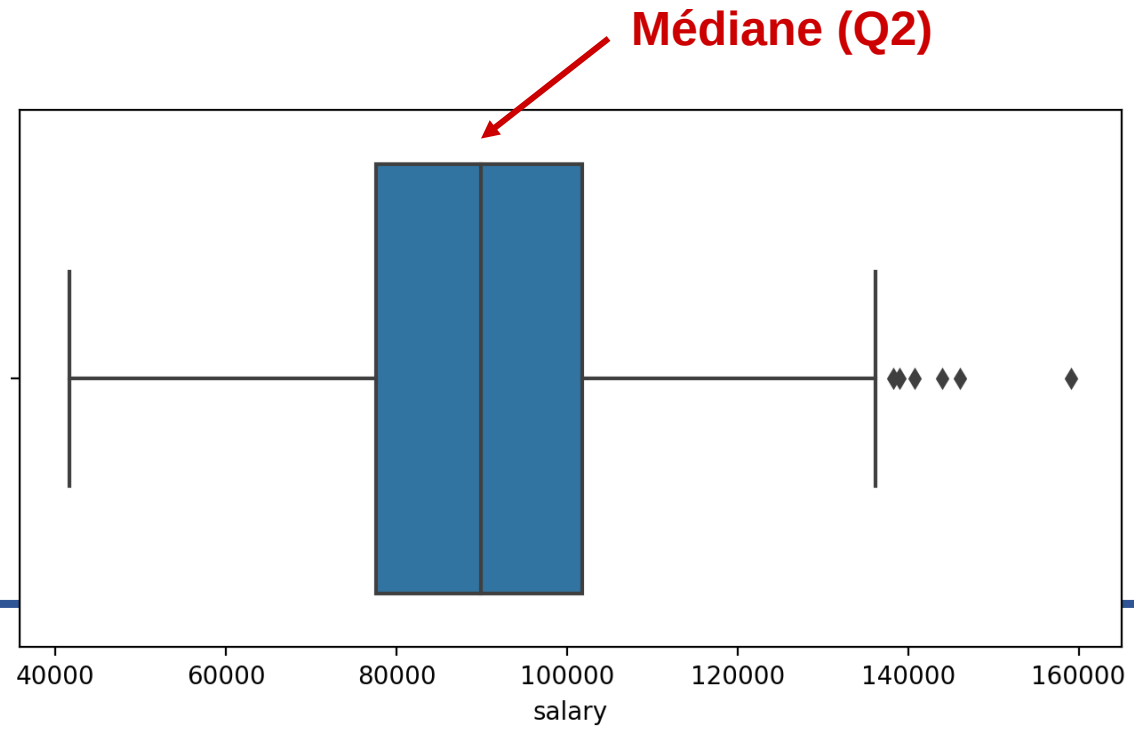

Graphes catégoriels

- IQR définit la largeur de la boîte

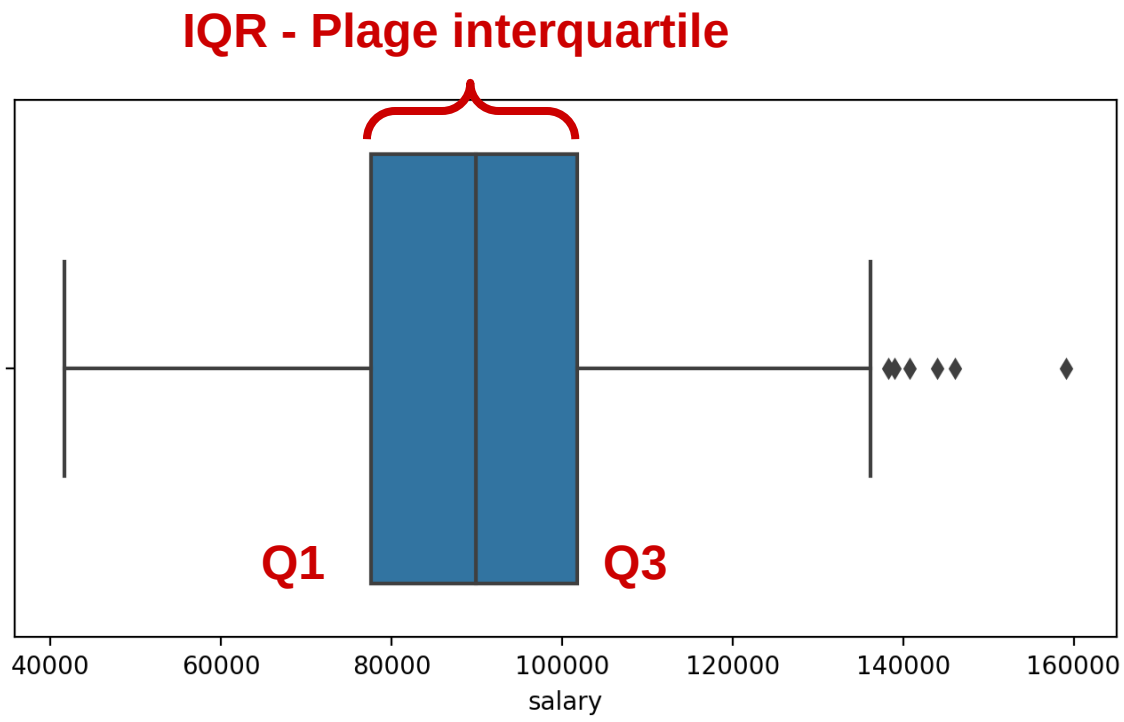

Graphes catégoriels

- 50 % de tous les points de données se trouvent à l'intérieur de la boîte

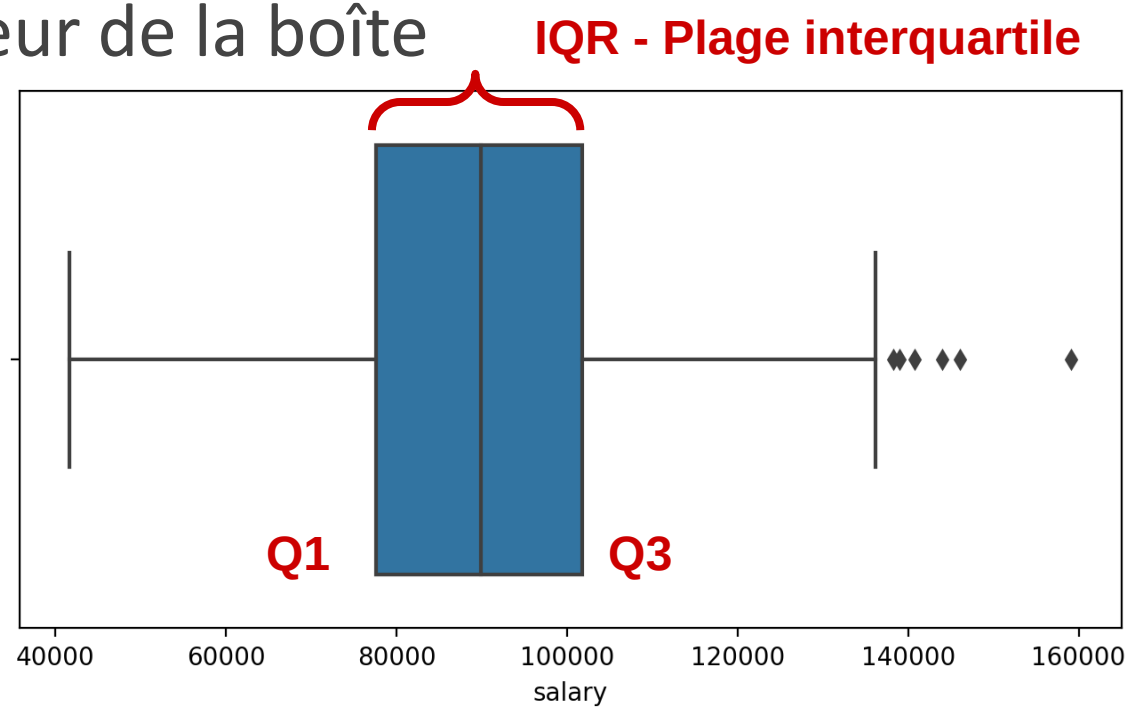

Graphes catégoriels

- Q1 est le 25e percentile

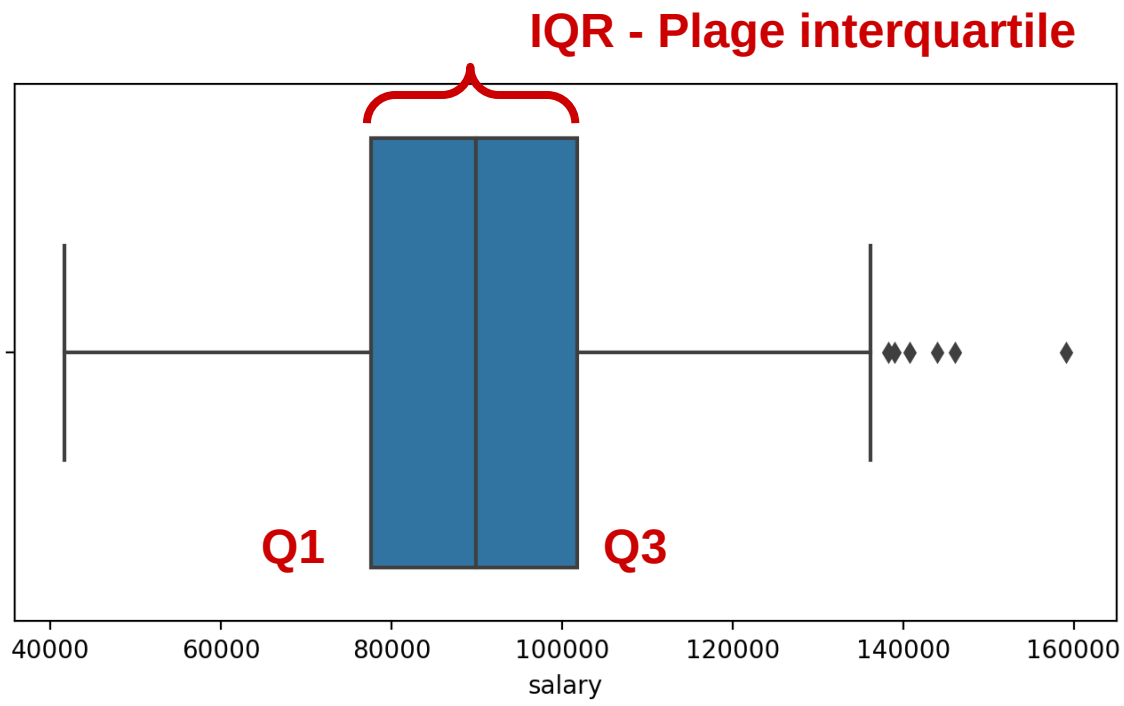

Graphes catégoriels

- 25 % des points de données sont inférieurs à Q1

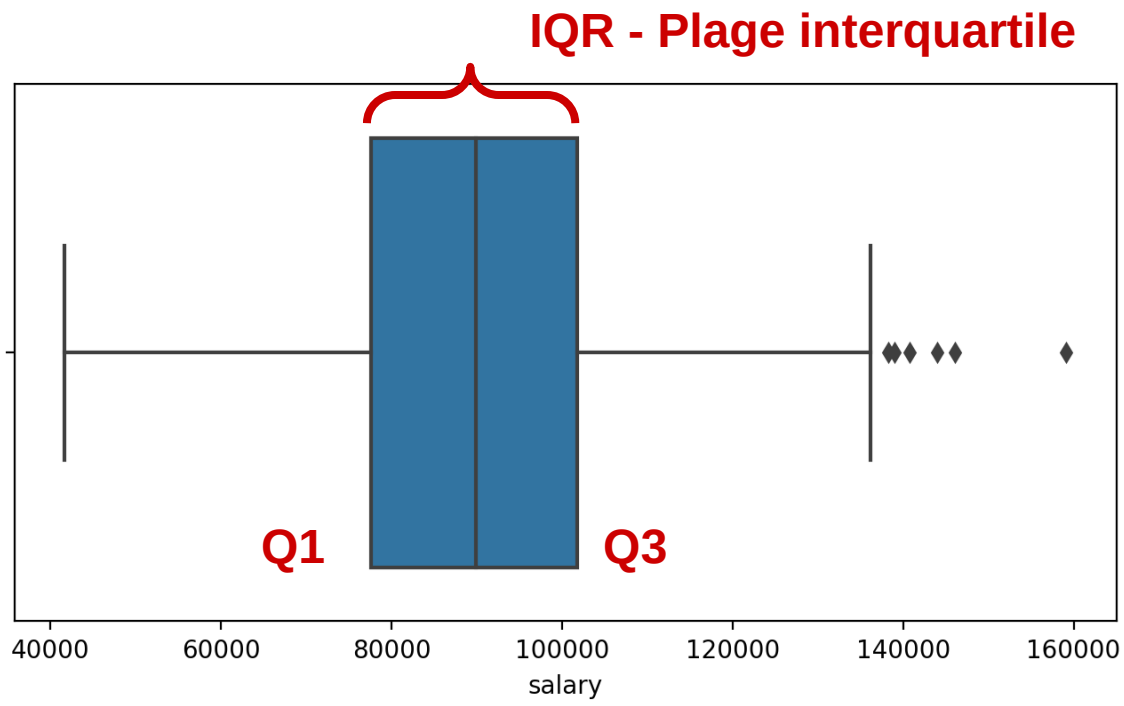

Graphes catégoriels

- Q3 est le 75e percentile

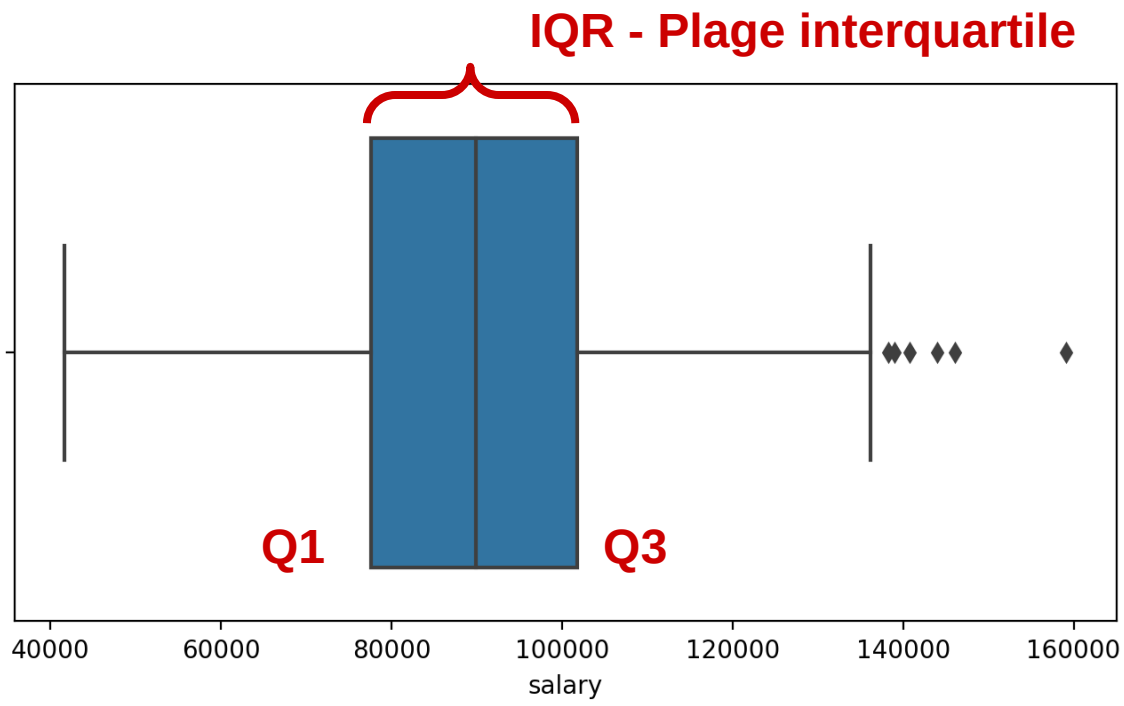

Graphes catégoriels

- 25 % de tous les points sont au-dessus de Q3
- la valeur en dessous de laquelle se trouve 75 % des données.

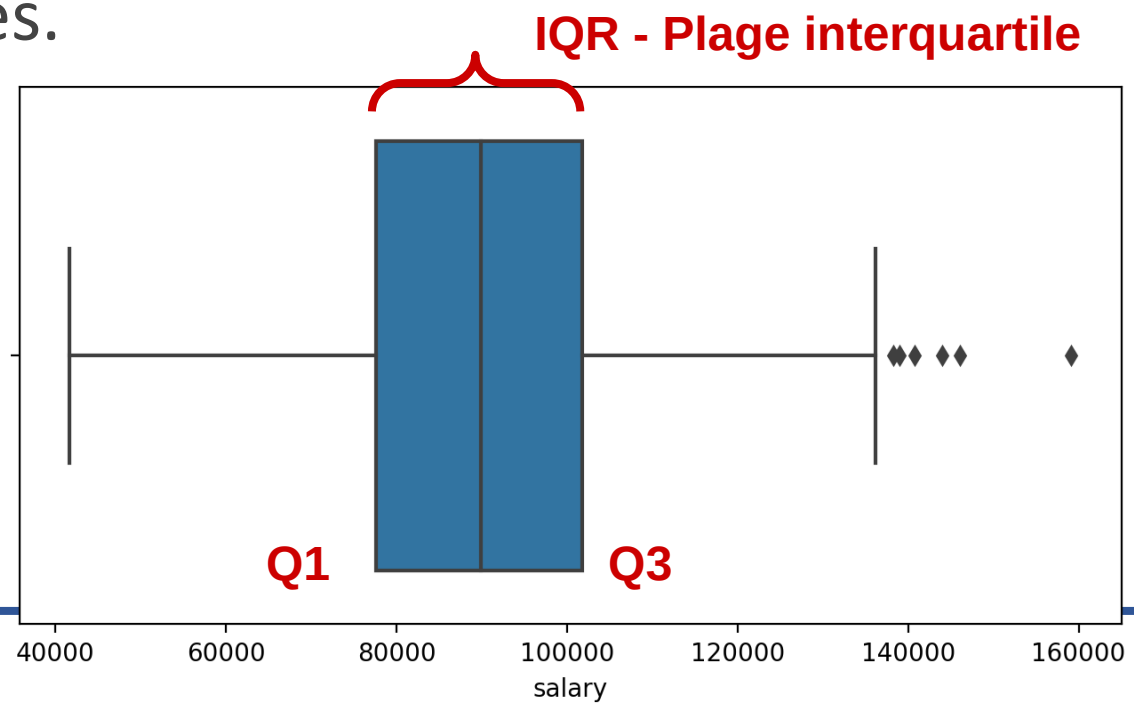

Graphes catégoriels

- Les « moustaches » sont définies par 1,5 × IQR

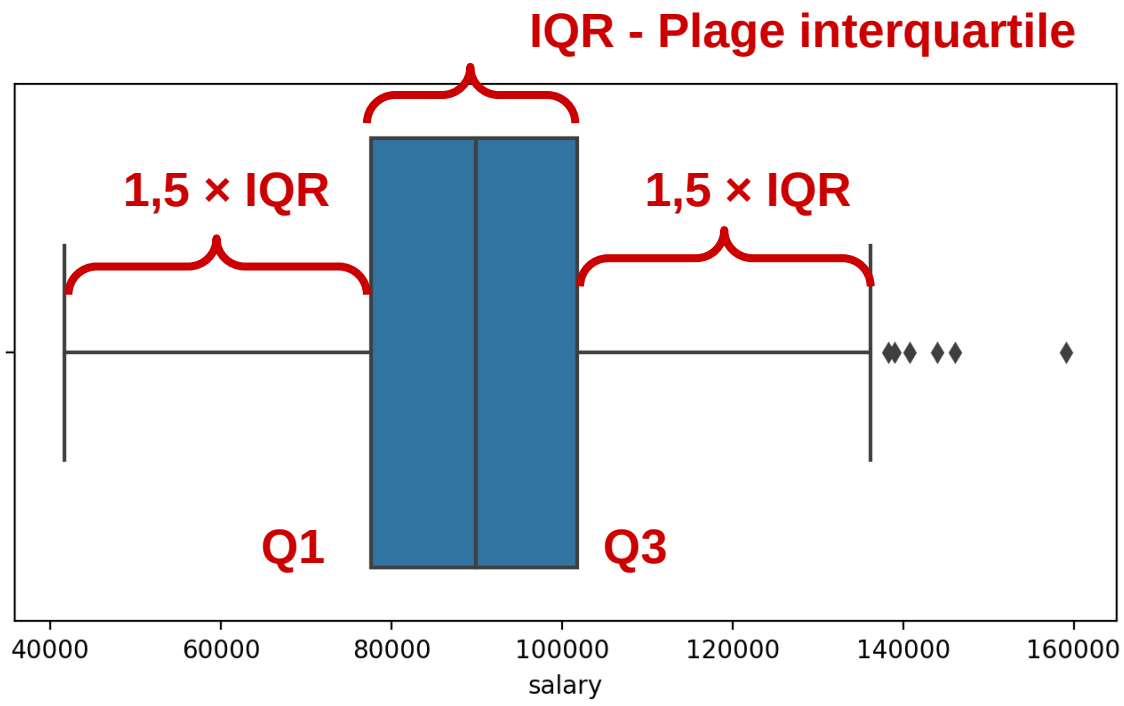

Graphes catégoriels

- En dehors des moustaches se trouvent des valeurs aberrantes

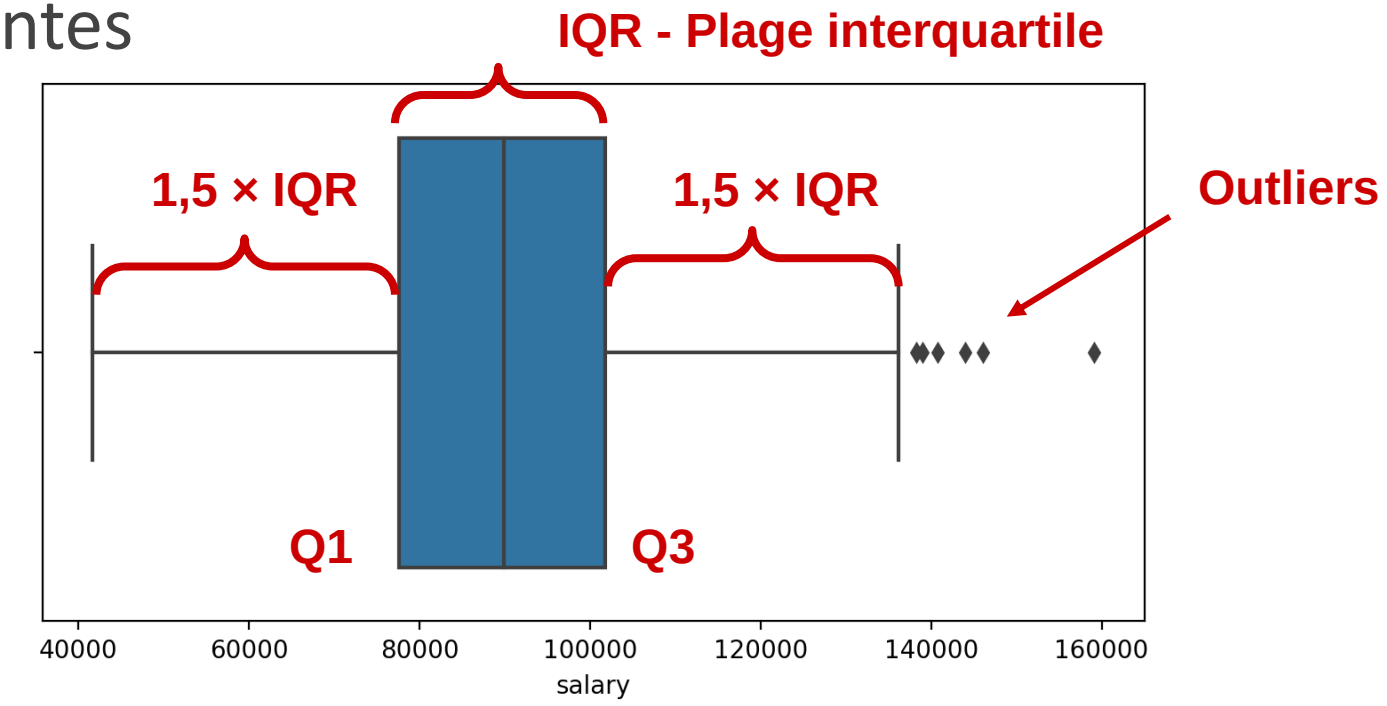

Graphes catégoriels

- Boxplot donne rapidement des informations sur la distribution statistique dans un format visuel

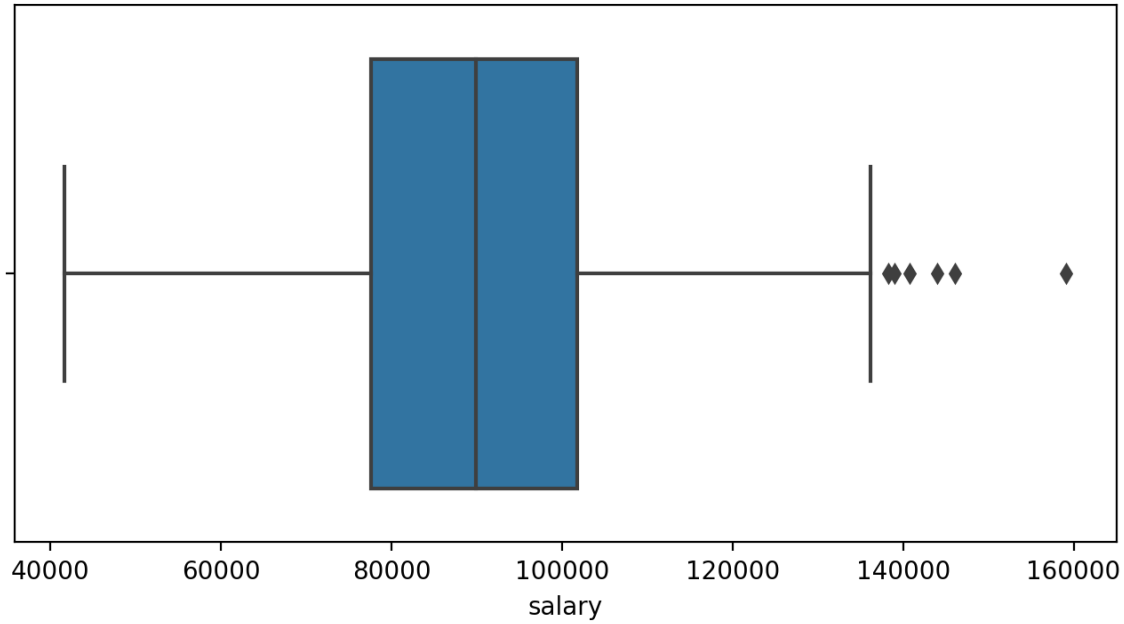

Graphes catégoriels

- Le boxplot peut être orienté verticalement ou horizontalement.
- La longueur des moustaches montre l’étendue des données "normales" (pas d’outliers).
- Les points au-delà des moustaches sont considérés comme des outliers (données aberrantes).

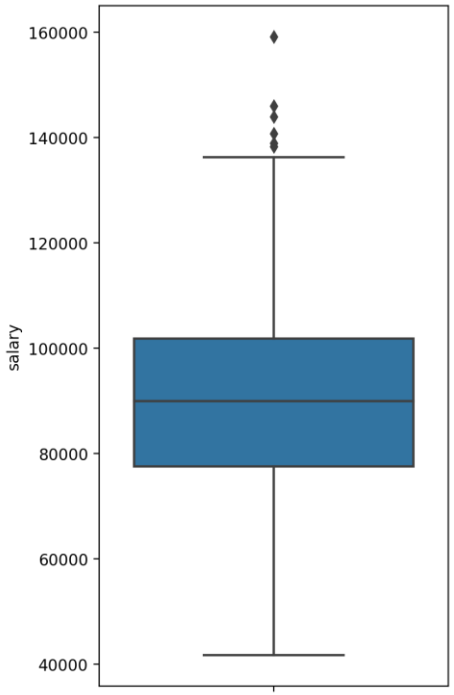

Graphes catégoriels

- Nous pouvons créer une boîte à moustaches par catégorie

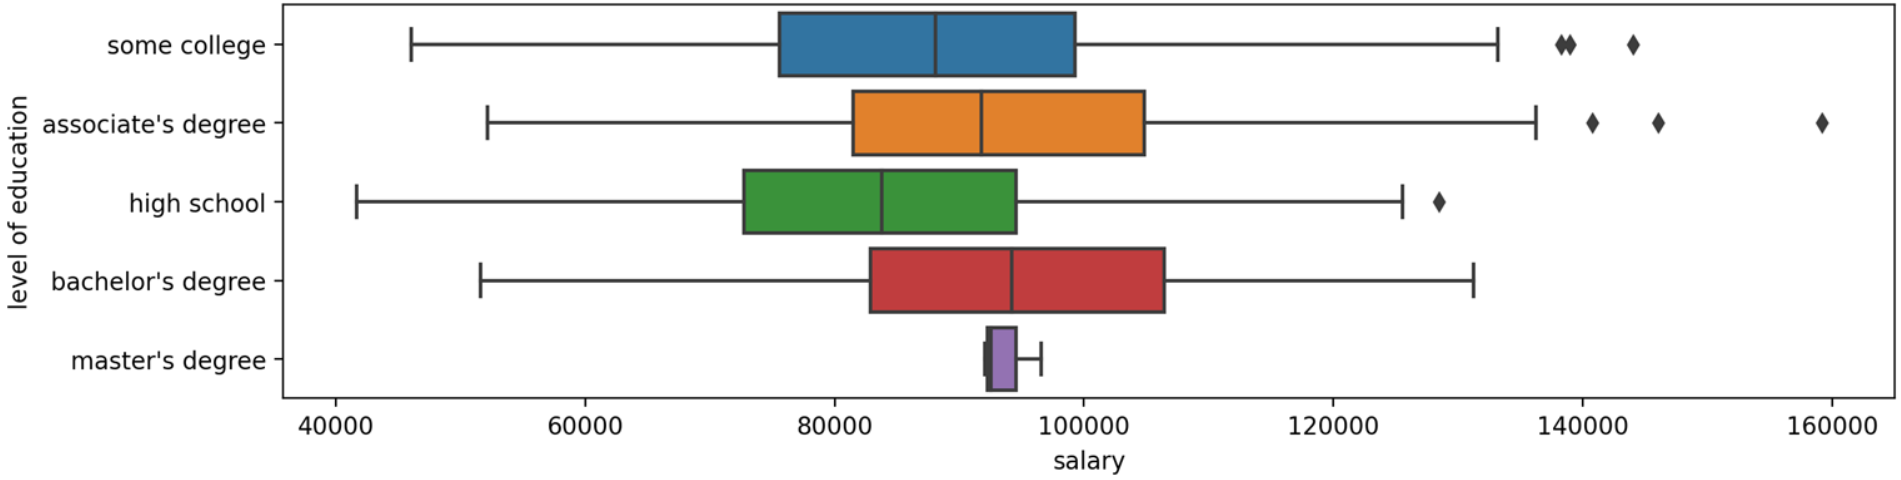

Graphes catégoriels

- Nous pouvons créer une boîte à moustaches par catégorie

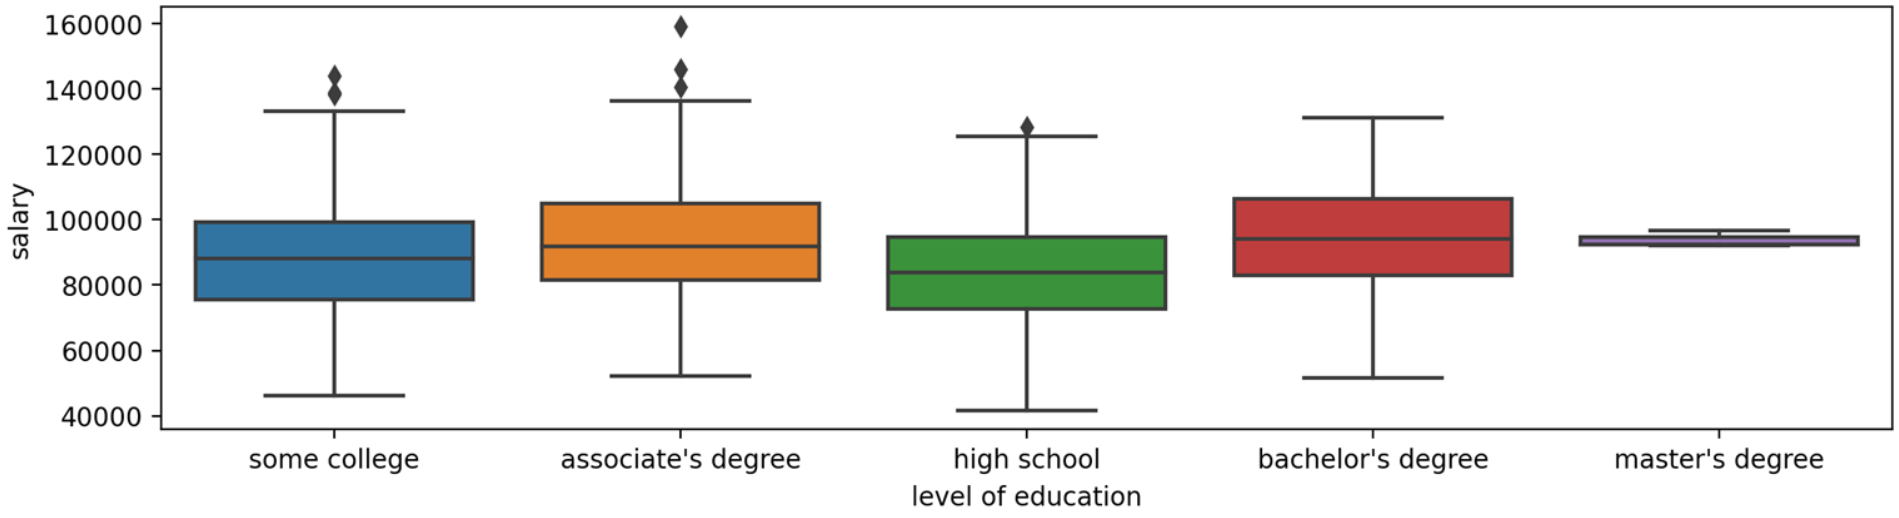

ViolinPlot

- ViolinPlot joue un rôle similaire à celui de la boîte à moustaches.
- Il affiche la densité de probabilité sur les données à l'aide d'un KDE.
- Nous pouvons l'imaginer comme un graphe KDE en miroir.

Rappel : KDE = Kernel Density Estimate (Estimation de la densité par noyau)
- le KDE est une méthode pour estimer la distribution de probabilité d’un ensemble de données de façon lisse.
- Plutôt que d’avoir un simple histogramme en barres, le KDE crée une courbe lisse qui "approxime" la forme générale des données.

violinPlot

- Nous pourrions alors le « refléter » :

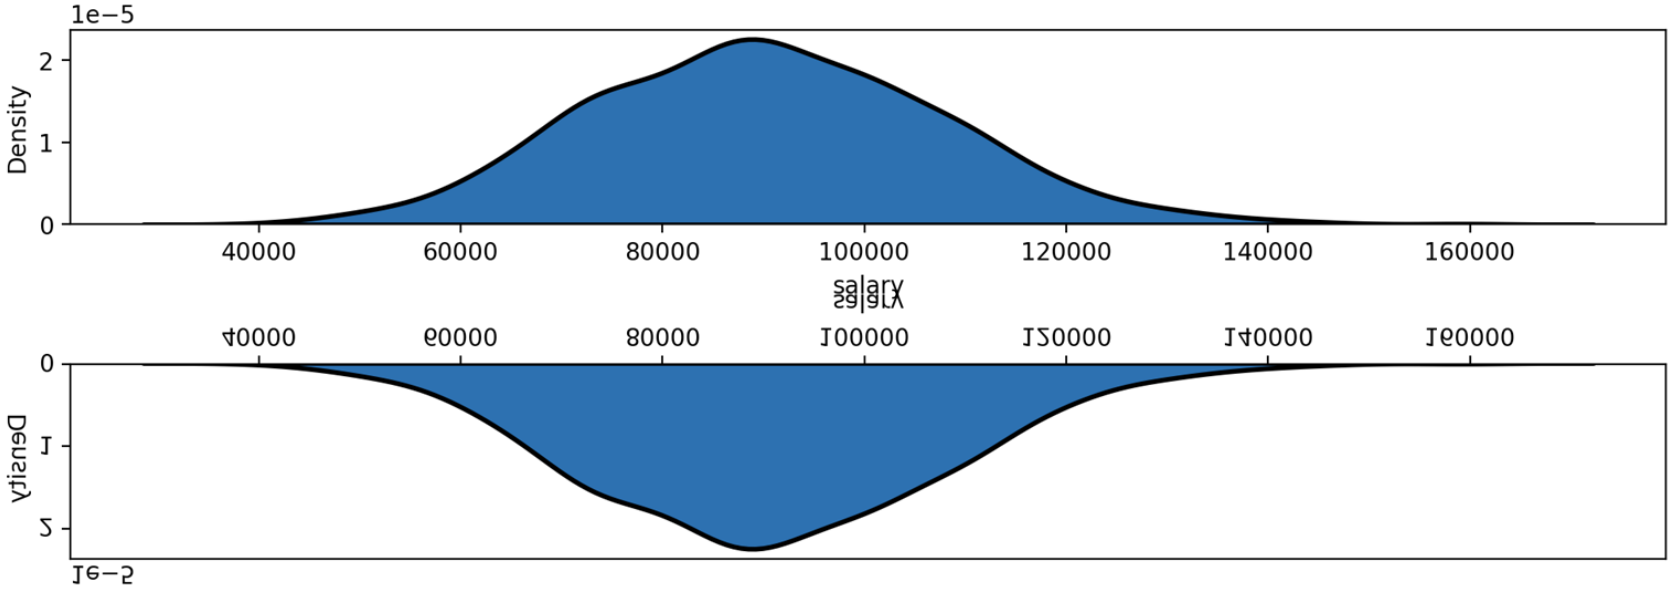

violinPlot

- Combinez-le ensuite pour obtenir le graphe en violon :

violinPlot

- Combinez-le ensuite pour obtenir le graphe en violon :

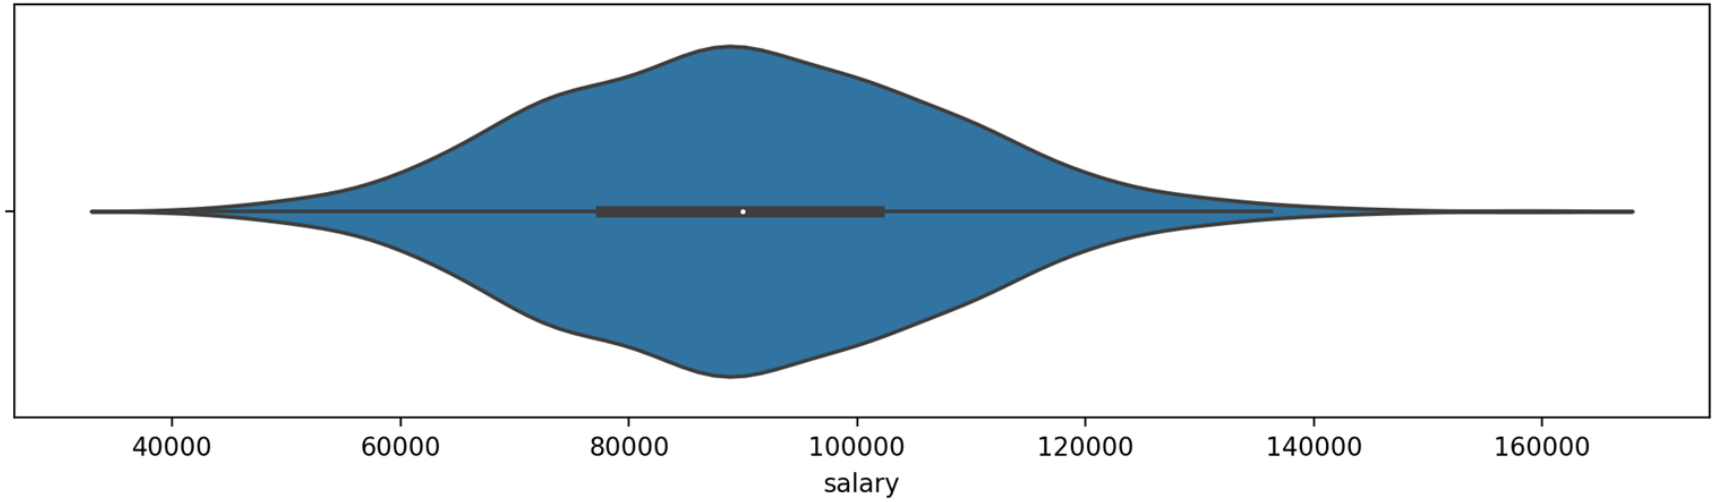

violinPlot

- Les graphes en violon peuvent ensuite être créées par catégorie.
- Ça donne une idée plus fine de la distribution, pas seulement des quantiles comme dans un boxplot.

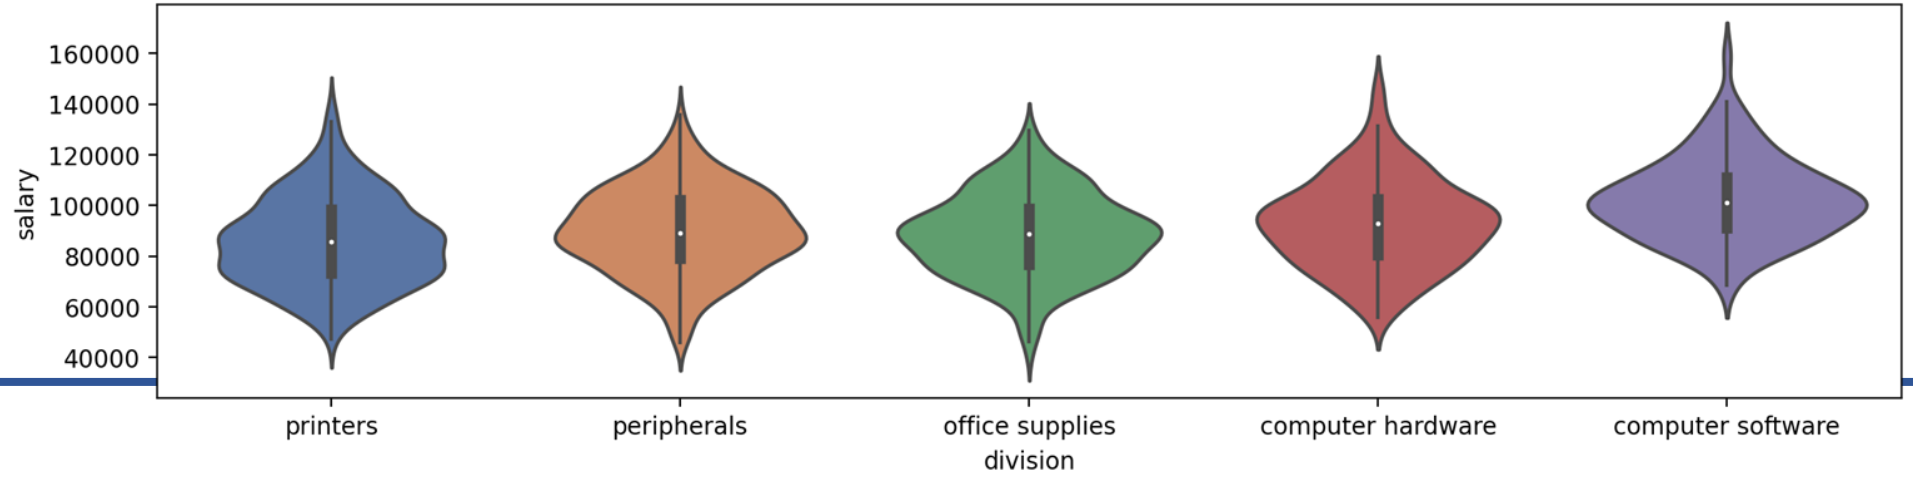

Notebook 4 : Graphes catégoriels – *Distribution au sein des catégories*

Graphiques de comparaison

Graphiques de comparaison

- Les tracés de comparaison sont essentiellement des versions bidimensionnelles des tracés que nous avons découverts jusqu'à présent.
- Le type principal de graphes abordé ici :
    - Pairplot()

Graphiques de comparaison

- Pairplot()
  - Le pairplot() est un moyen rapide de comparer toutes les colonnes numériques d'un DataFrame.
  - Il crée automatiquement un histogramme pour chaque colonne et une comparaison de nuages de points entre toutes les combinaisons possibles de colonnes.

Graphiques de comparaison

- Pairplot()

  Avertissement!

  - pairplot() peut être gourmand en CPU et en RAM pour les grands DataFrames avec de nombreuses colonnes.
  - C'est une bonne idée de commencer par filtrer uniquement les colonnes qui vous intéressent.

Graphiques de comparaison

- Pairplot()

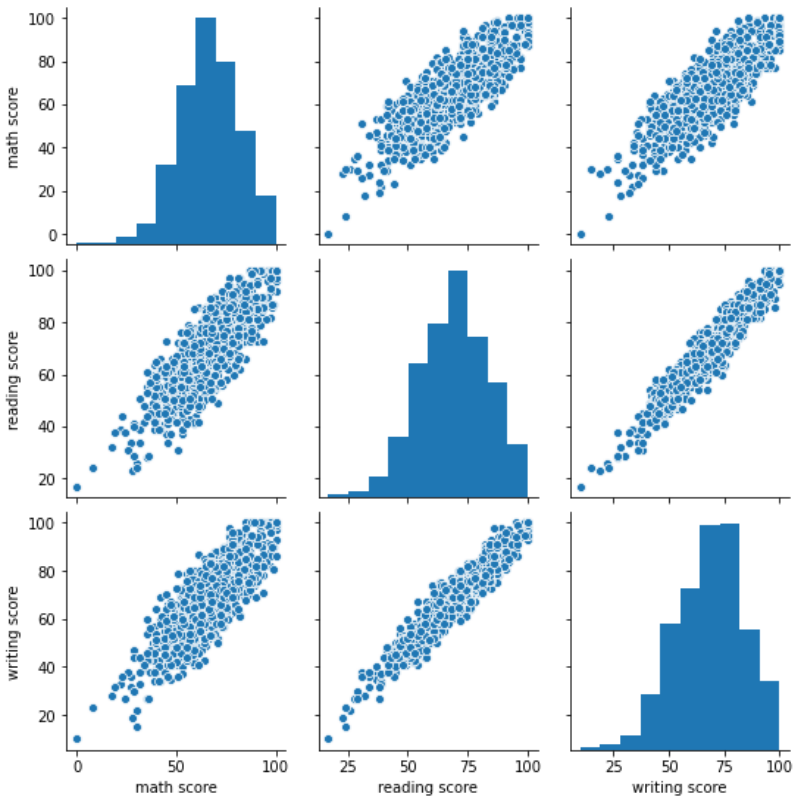

Graphiques de comparaison

- Pairplot()

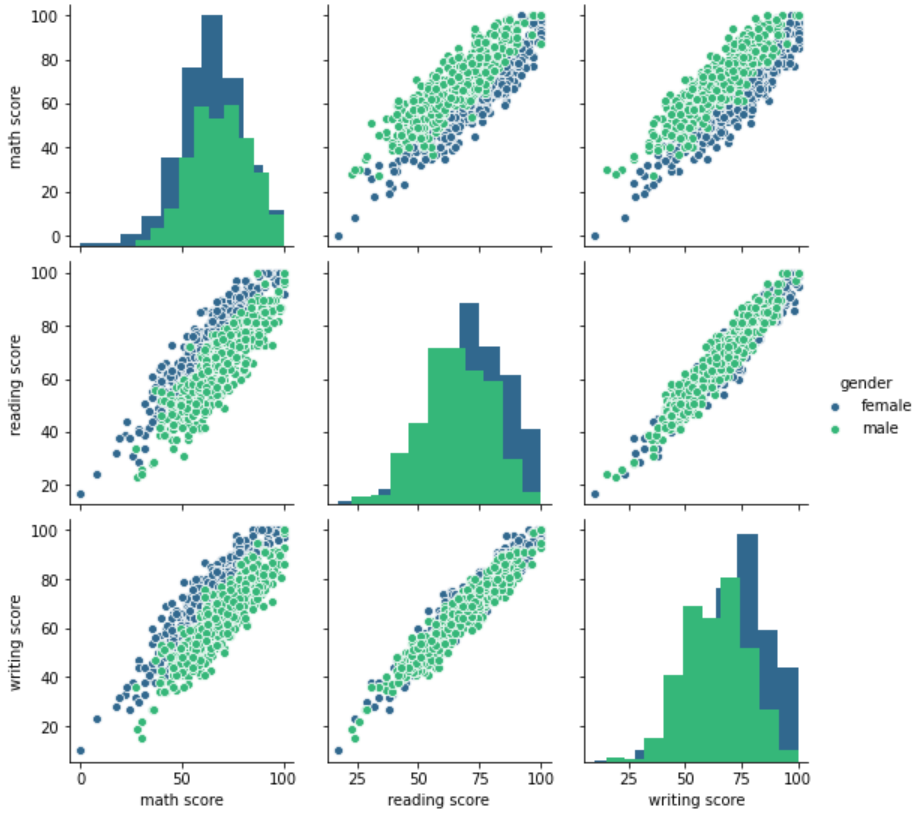

Graphiques de comparaison

- Pairplot()

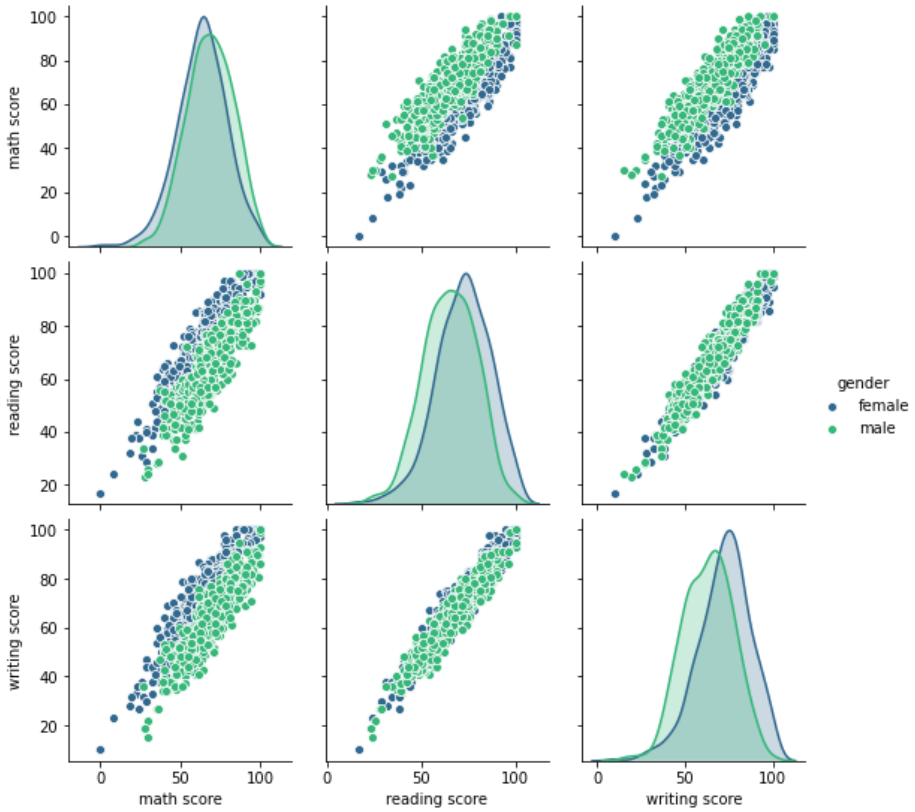

Graphiques de comparaison

- Pairplot()

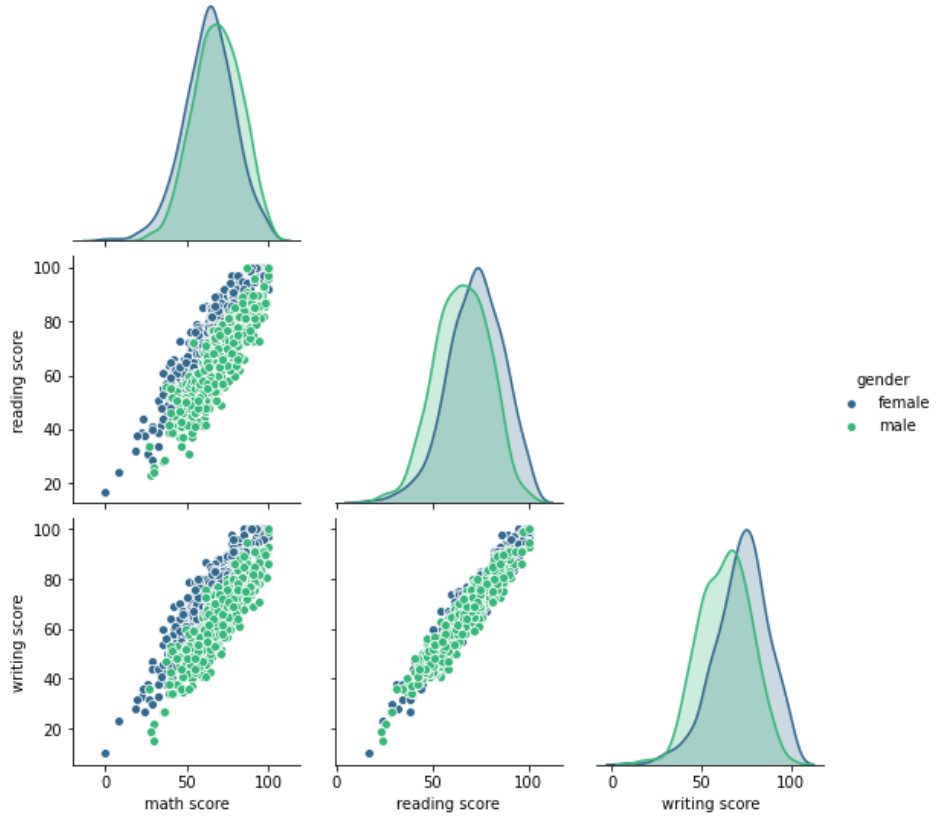

Notebook 5 : Graphiques de comparaison

Grilles Seaborn

Grilles Seaborn

- Les appels de grille Seaborn utilisent Matplotlib subplots() pour créer automatiquement une grille basée sur une colonne catégorielle.
- Au lieu de transmettre un nombre spécifique de colonnes ou de lignes pour les sous-graphes, nous pouvons simplement transmettre le nom de la colonne et Seaborn mappera automatiquement la grille des sous-graphes.
- De nombreux appels de graphes intégrés à Seaborn fonctionnent sur ce système de grille.
- L'appel direct du système de grille permet aux utilisateurs de personnaliser fortement les tracés.

Grilles Seaborn

- Création de sous-graphes basés sur des grilles :

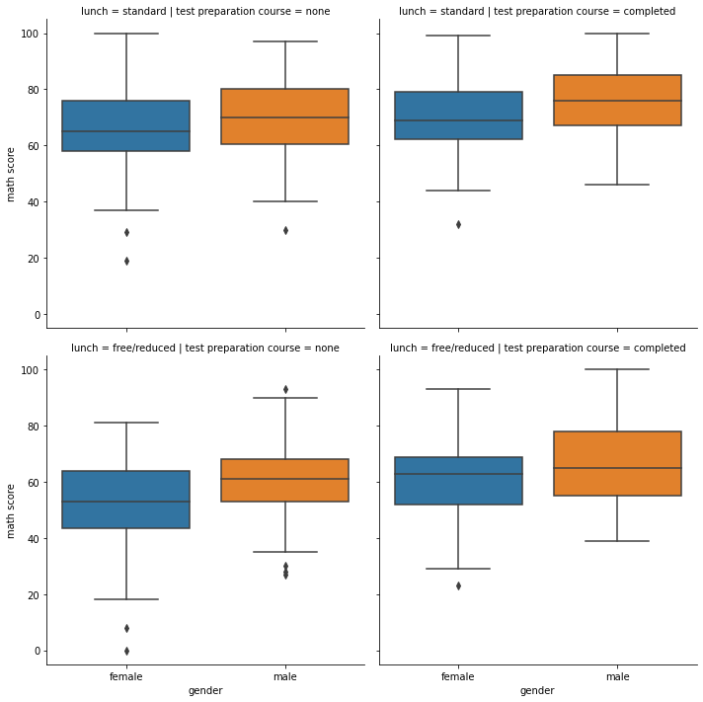

Grilles Seaborn

- Cartographier des tracés basés sur la grille pairplot() :

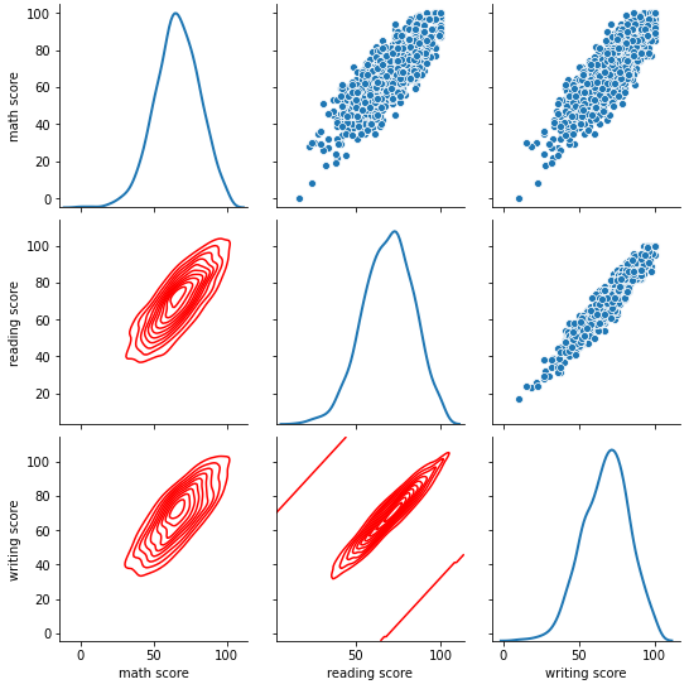

Fonction	Usage principal	Type de données	Facettage automatique	Graphiques supportés
`catplot`	Visualisation simplifiée des données catégoriques	Variables catégoriques + numériques	Oui (`row` , `col` , `hue`)	Boxplot, violin, barplot, swarm, etc.
`FacetGrid`	Création flexible de grilles de graphiques	Variables catégoriques	Oui	Tous types (graphes personnalisés)
`PairGrid`	Matrice de graphiques entre variables multiples	Variables numériques	Non (carré selon variables)	Scatter, kde, histogrammes, etc.

Notebook 6 : Grilles Seaborn

Tracés matriciels

Tracés matriciels

- Les tracés matriciels sont l’équivalent visuel de l’affichage d’un tableau croisé dynamique.
- Le tracé matriciel affiche toutes les données transmises, visualisant toutes les valeurs numériques dans un DataFrame.
- Note!
    - Tous les DataFrame ne constituent pas un choix valable pour un tracé matriciel tel qu'une carte thermique.

Tracés matriciels

- Le type principal de tracés matriciels :
  - HeatMap() : Affiche visuellement la distribution des valeurs de cellule avec un mappage de couleurs.

Exemple:

Countries	Birth rate	Mortality rate	Life expectancy	Infant mortality rate	Growth rate
AFRICA	32.577	7.837	63.472	44.215	24.40
ASIA	15.796	7.030	73.787	23.185	8.44
EUROPE	10.118	11.163	78.740	3.750	0.38
LATIN AMERICA AND THE CARIBBEAN	15.886	6.444	75.649	14.570	8.89
NORTHERN AMERICA	11.780	8.833	79.269	5.563	6.11
OCEANIA	16.235	6.788	78.880	16.939	12.79
WORLD	17.963	7.601	72.766	27.492	10.36

Tracés matriciels

- Carte de chaleur

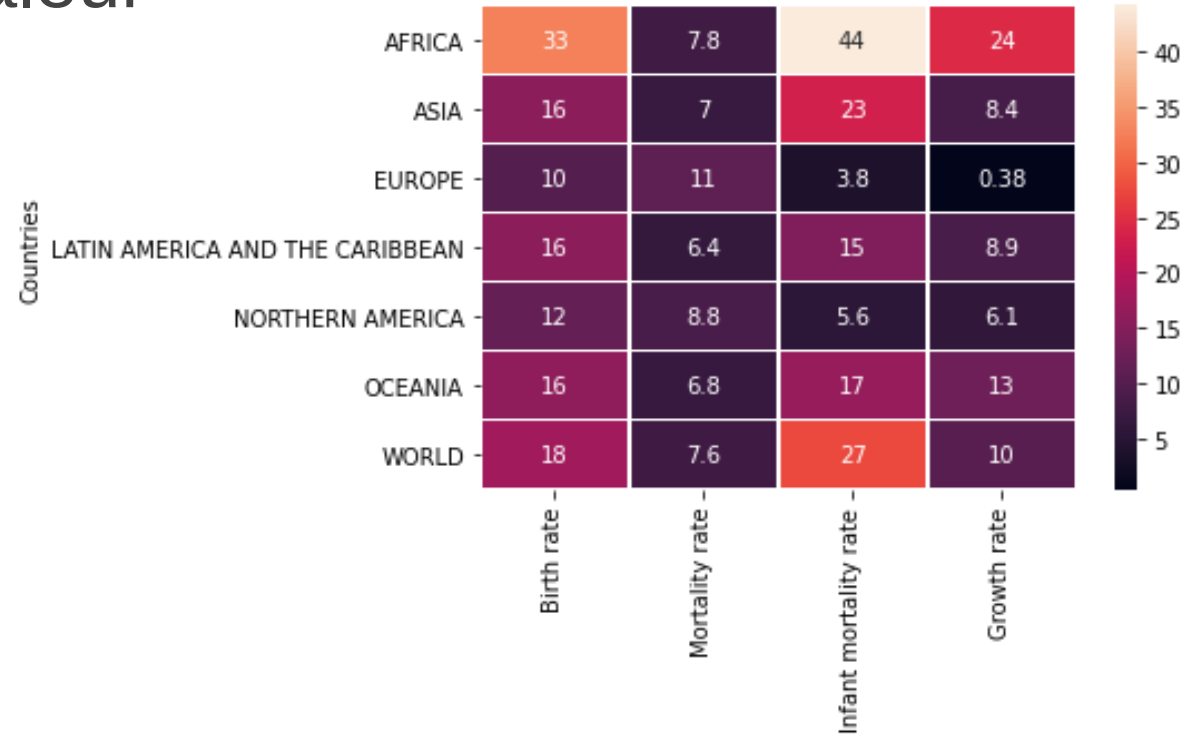

Tracés matriciels

- Notez qu'une HeatMap devrait idéalement avoir toutes les cellules dans les mêmes unités, de sorte que le mappage des couleurs a du sens sur l'ensemble du DataFrame.
- Dans ce cas particulier, toutes les valeurs étaient des « taux » de croissance ou de changement en pourcentage dans carte de chaleur.

Tracés matriciels

- Si nous incluons l'âge :

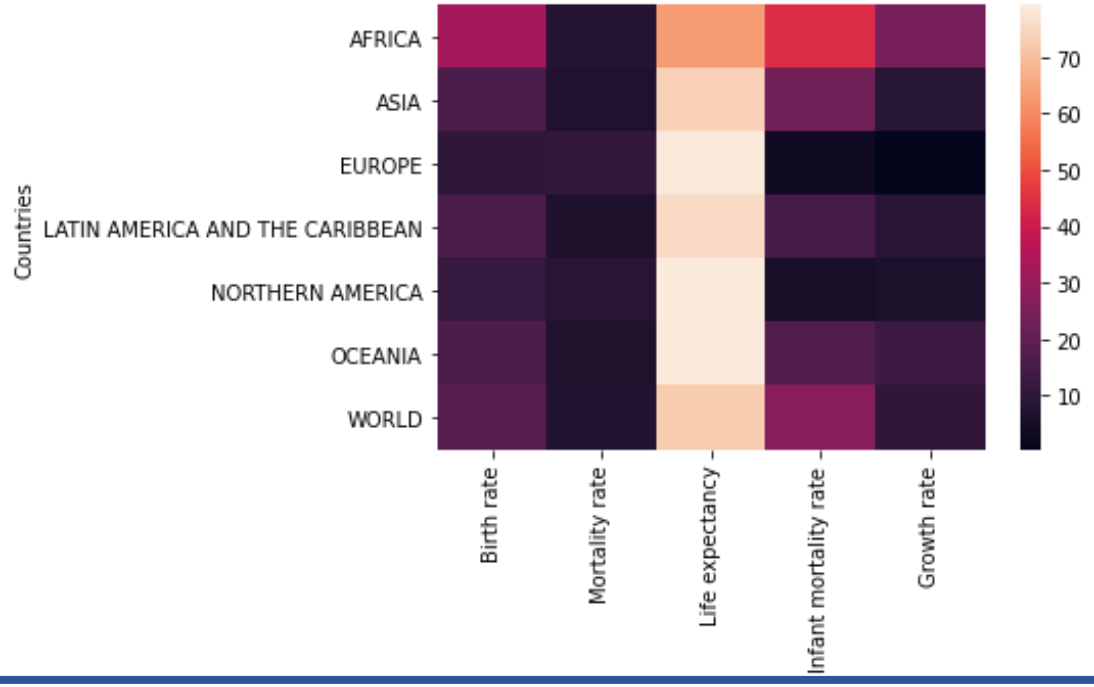

Notebook 7 : HeatMaps

Notebook 8 : Exercices Seaborn